A 传统通用云 vs. AI 数据中心：六维架构重心迁移
传统云：OS/进程接口
一机切分多租户实例
AI 工厂：上下文/模型接口
多卡聚合单一实例
传统云：异步 RPC 流量
局部无状态副本容错
AI 工厂：高频集合通信
全局同步屏障扩散
传统云：资源超分复用
看重 CPU/内存分配率
AI 工厂：齐步协同调度
看重 SLO 产出与 MPG
B 经典计算机系统六大设计模式在 LLM 系统中的映射
1 分层与缓存
页缓存 → 前缀 KV
与三级状态池
2 重算换搬运
重物化 → 检查点
与 FA 在线重算
3 旁路零拷贝
内核旁路 → RDMA
与 GDS 直通
4 重叠与流水
双缓冲 → 算子流水
与通信重叠
5 批量与分摊
批量 I/O → 连续批
分摊权重读取
6 解耦与池化
存算分离 → PD/AF
与集中 KV 池