## A 传统通用云 vs. AI 数据中心：六维架构重心迁移（D11-01）

| 传统云 | AI 工厂 |
| --- | --- |
| 传统云：OS/进程接口<br>一机切分多租户实例 | AI 工厂：上下文/模型接口<br>多卡聚合单一实例 |
| 传统云：异步 RPC 流量<br>局部无状态副本容错 | AI 工厂：高频集合通信<br>全局同步屏障扩散 |
| 传统云：资源超分复用<br>看重 CPU/内存分配率 | AI 工厂：齐步协同调度<br>看重 SLO 产出与 MPG |

## B 经典计算机系统六大设计模式在 LLM 系统中的映射（D11-03）

| 1 分层与缓存 | 2 重算换搬运 | 3 旁路零拷贝 |
| --- | --- | --- |
| 页缓存 → 前缀 KV<br>与三级状态池 | 重物化 → 检查点<br>与 FA 在线重算 | 内核旁路 → RDMA<br>与 GDS 直通 |
| **4 重叠与流水** | **5 批量与分摊** | **6 解耦与池化** |
| 双缓冲 → 算子流水<br>与通信重叠 | 批量 I/O → 连续批<br>分摊权重读取 | 存算分离 → PD/AF<br>与集中 KV 池 |