A 五大 AI 负载范式的算术强度与主瓶颈迁移
1 单轮对话
状态单次读取
受限 HBM 带宽
2 自主智能体
90% 前缀复用
受限状态池容量
3 全双工语音
12.5 Hz 双流
80 ms 硬实时墙
4 合成数据工厂 (Ch13)
无首字约束 · 追求吞吐/美元
5 科学智能 AI4S (Ch22)
三角注意力与长序列通信
B 三维特征空间：算术强度 · 状态驻留 · 尾延迟
算术强度 I
单步解码 ~1
合成批 >200
状态驻留时长
单轮毫秒即释
智能体跨小时
尾延迟敏感度
语音 <80 ms
合成容忍分钟
范式转移：主瓶颈从显存带宽转向状态池容量、微秒抖动与跨卡通信