A 全书 24 章五大算力象限与前沿负载扩展谱系

1 搜广推 HSTU

万亿表三级缓存
M-FALCON 44.8x

2 后自回归生成

dLLM 块并行去噪
BLT 动态字节分块

3 极低延迟推理

晶圆级片上 SRAM
16.5 us 持久内核

4 去中心化训练 (Ch16)

DiLoCo 降带宽 2000x

5 全栈与自演进 (Ch24)

FlashMLA · RLVR 合成

B 24 章全栈四维物理边界：算术强度 · 状态介质 · 互联 · 自治

存储介质谱系

44GB 片上 SRAM
至百 PB 3FS 池

通信带宽跨度

NVL576 3.6 TB/s
至广域 350 Mbps

延迟与自治闭环

高频量化 <25 us
AIOps 42s 自愈

全书主线：围绕算术强度、状态局部性、关键路径掩盖与能效比演进