A 全栈时间线与跨层关键路径有向无环图（DAG）
L1 主机调度流
Python API → 连续批编排 → 算子下发
L2 GPU 计算流
CUPTI 追踪 · Prefill/Decode 算子执行
L3 网卡通信流
RDMA 队列 · AllReduce/All-to-All 传输
B 三类剖析器协同定位关键路径暴露量
XProf
统一全局时间轴
Roofline 瓶颈归因
ProfInfer
eBPF 无侵入追踪
捕获缺页与锁争用
StriaTrace
锚定跨卡同步屏障
逆向定位慢节点流
关键路径判据：仅优化最长路径上的非重叠暴露段才能降低端到端延迟