L6 应用与任务
对话、编程助手、多模态 · 延迟与吞吐 SLO
L5 模型与负载
稠密/MoE 架构、长上下文 · 算力与显存需求
L4 训练与推理系统
分布式并行、请求路由、连续批处理与 KV 管理
L3 算子与编译运行时
算子融合、计算图编译、显存分配与异步流调度
L2 处理器与存储
GPU / NPU / CPU · SRAM、HBM 与持久化存储
L1 互联与数据中心
片间互联（Scale-Up）、跨机网络、供电与散热
跨层平台治理
资源调度
算力分配
齐步排程
运行环境
容器镜像
故障隔离
可观测性
全栈追踪
能效核算
共同物理边界：先进封装 · 机架供电与液冷散热 · 集群高可用