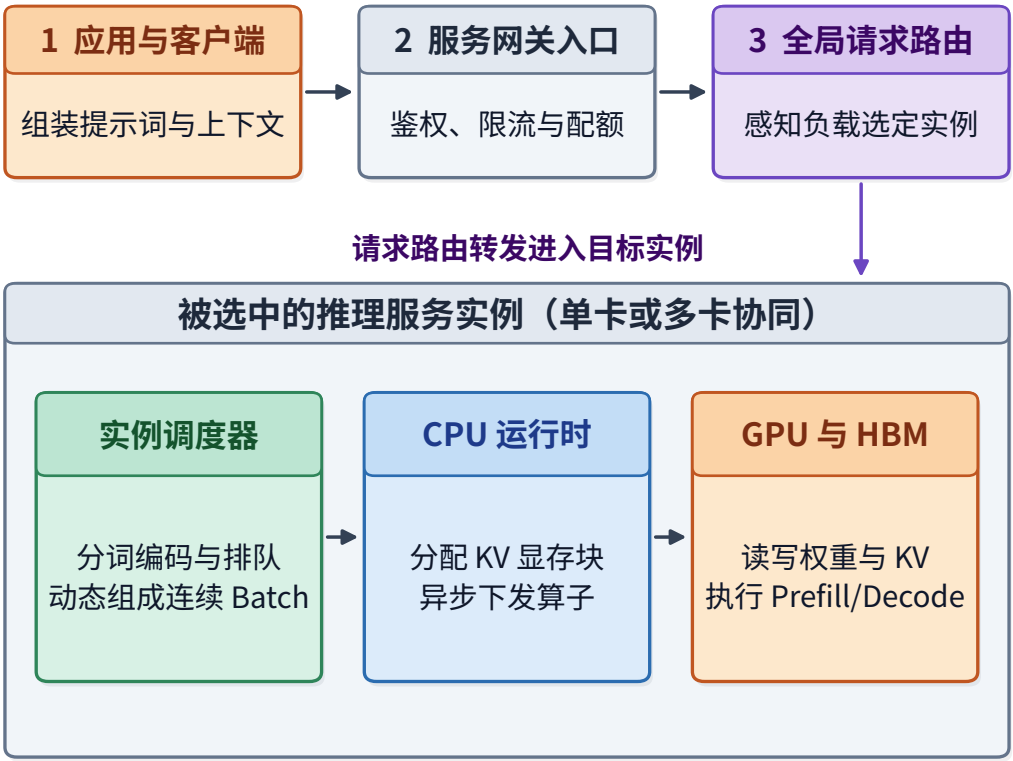
1 应用与客户端
组装提示词与上下文
2 服务网关入口
鉴权、限流与配额
3 全局请求路由
感知负载选定实例
请求路由转发进入目标实例
被选中的推理服务实例（单卡或多卡协同）
实例调度器
分词编码与排队
动态组成连续 Batch
CPU 运行时
分配 KV 显存块
异步下发算子
GPU 与 HBM
读写权重与 KV
执行 Prefill/Decode