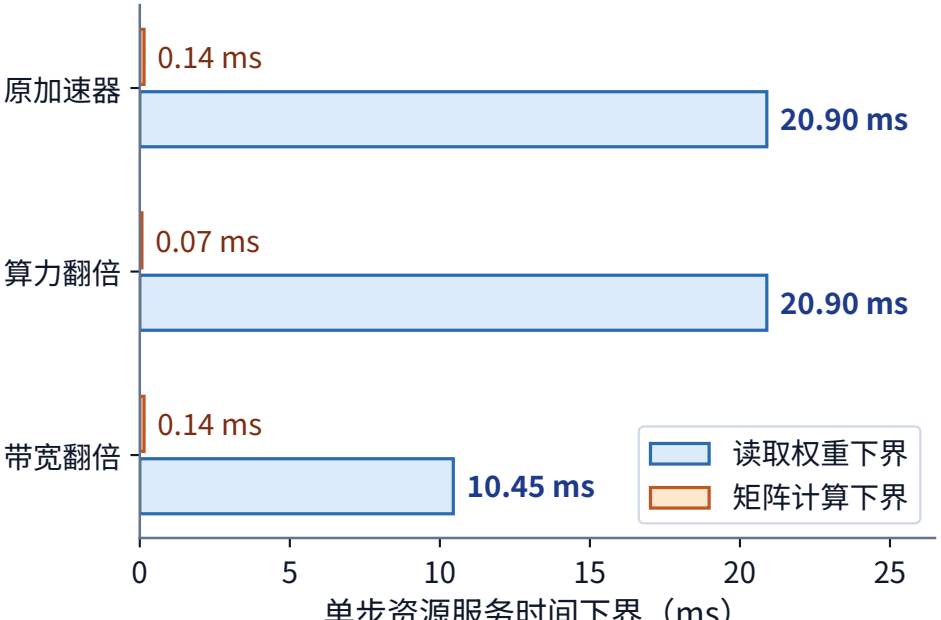
原加速器
0.14 ms
20.90 ms
算力翻倍
0.07 ms
20.90 ms
带宽翻倍
0.14 ms
10.45 ms
读取权重下界
矩阵计算下界
0
5
10
15
20
25
单步资源服务时间下界（ms）