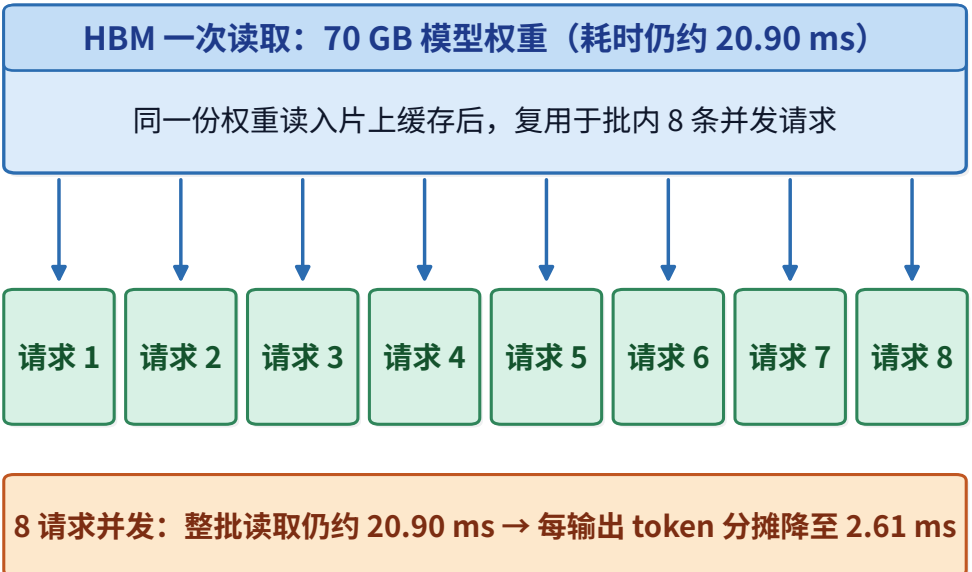
HBM 一次读取：70 GB 模型权重（耗时仍约 20.90 ms）
同一份权重读入片上缓存后，复用于批内 8 条并发请求
请求 1
请求 2
请求 3
请求 4
请求 5
请求 6
请求 7
请求 8
8 请求并发：整批读取仍约 20.90 ms → 每输出 token 分摊降至 2.61 ms