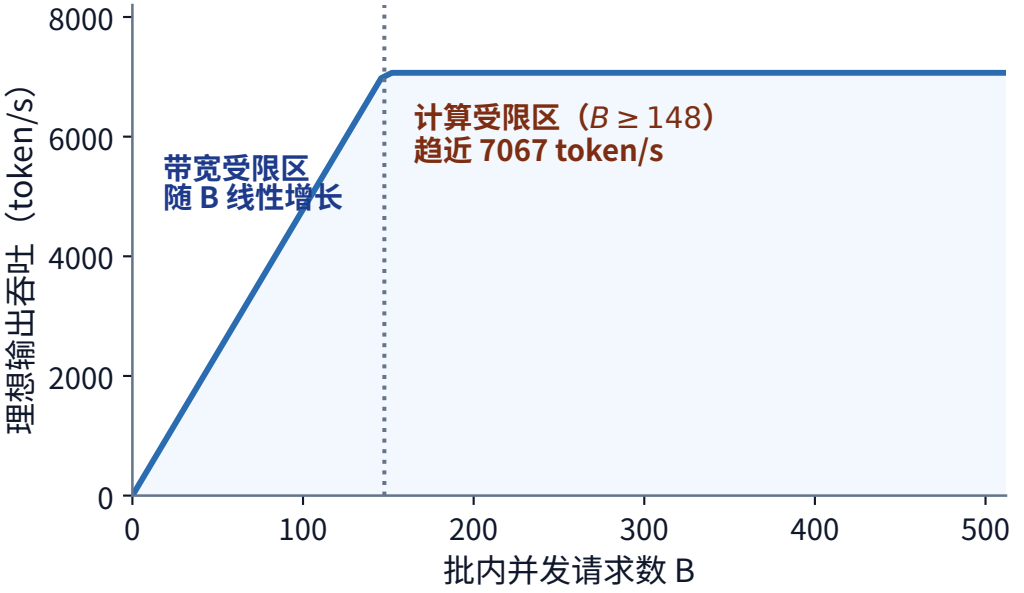
8000
6000
4000
2000
0
理想输出吞吐（token/s）
0
100
200
300
400
500
批内并发请求数 B
带宽受限区
随 B 线性增长
计算受限区（$B \geq 148$）
趋近 7067 token/s