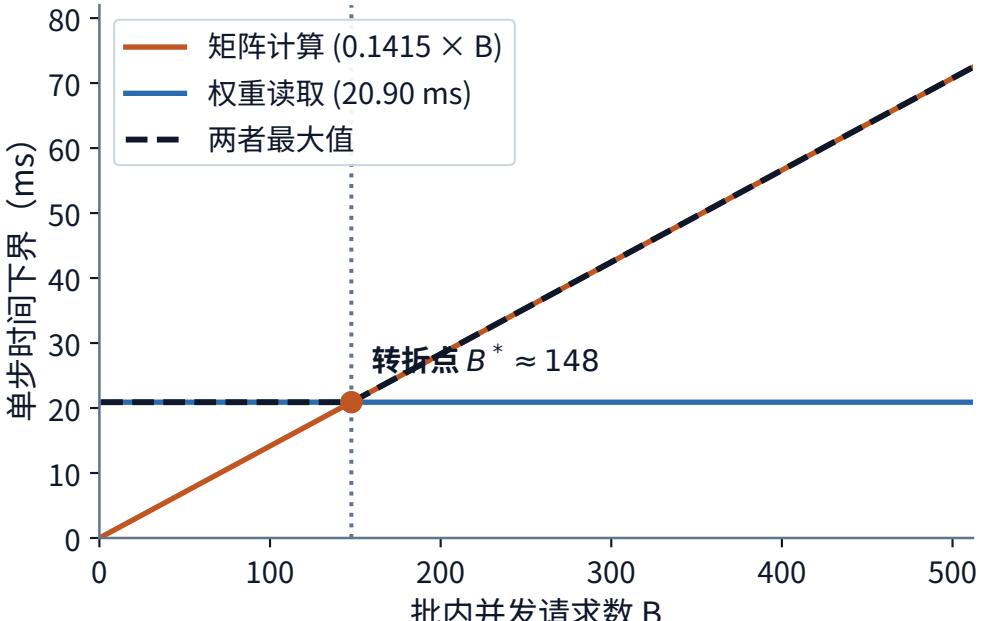
矩阵计算 (0.1415 × B)
权重读取 (20.90 ms)
两者最大值
转折点 $B^* \approx 148$
单步时间下界（ms）
批内并发请求数 B
0
10
20
30
40
50
60
70
80
0
100
200
300
400
500