第一部分 模型与负载（第 1–3 章）

1 初识 AI Infra
2 模型架构
3 推理与训练负载

第二部分 芯片与系统（第 4–7 章）

4 加速器架构
5 算子与运行时
6 超节点
7 数据中心网络

第三部分 推理、训练与端边云调度（第 8–12 章）

8 推理优化
9 分布式推理
10 训练系统
11 资源调度与运行环境
12 端边云协同

第四部分 跨层协同、超大规模集群与科学负载（第 13–24 章）

13 AI 原生存储与数据底座
14 模型与系统硬件协同设计
15 吉瓦级数据中心与电力热学
16 机密 AI 计算与安全沙箱
17 多模态、视频 DiT 与世界模型
18 大规模后训练与推理时扩展
19 具身智能（VLA）与物理仿真
20 十万卡集群可靠性与基准科学
21 自主智能体与分层 KV 记忆
22 全双工实时语音与原生全模态
23 百亿亿次数据工程与合成工厂
24 科学智能（AI4Science）底座

第五部分 前沿生成范式、源码解剖与自演进系统（第 25–30 章）

25 生成式推荐与 GPU 向量库
26 扩散语言模型、无分词与记忆网
27 晶圆级 SRAM、微秒 AI 与三值化
28 广域网去中心化训练与安全水印
29 DeepSeek 开源全栈源码级解剖
30 自演进 AI Infra 与三十章大收束