第一部分 模型与负载（第 1–3 章）

1 初识 AI Infra
2 模型架构
3 推理与训练负载

第二部分 芯片与硬件系统（第 4–7 章）

4 加速器架构
5 算子与运行时
6 超节点
7 数据中心网络

第三部分 推理、训练与调度系统（第 8–12 章）

8 推理优化
9 分布式推理
10 训练系统
11 资源调度与运行环境
12 端边云协同

第四部分 数据、集群底座与后训练系统（第 13–17 章）

13 存储系统与数据工程
14 智算中心与电力热学系统
15 集群可靠性与基准评测
16 机密计算与可信安全系统
17 后训练与强化学习系统

第五部分 多模态、领域负载与前沿架构（第 18–24 章）

18 自主智能体系统
19 多模态生成与实时语音
20 具身智能与物理仿真
21 推荐检索与向量数据库
22 科学计算智能系统
23 软硬件协同与新型架构
24 全栈跨层优化与自演进系统