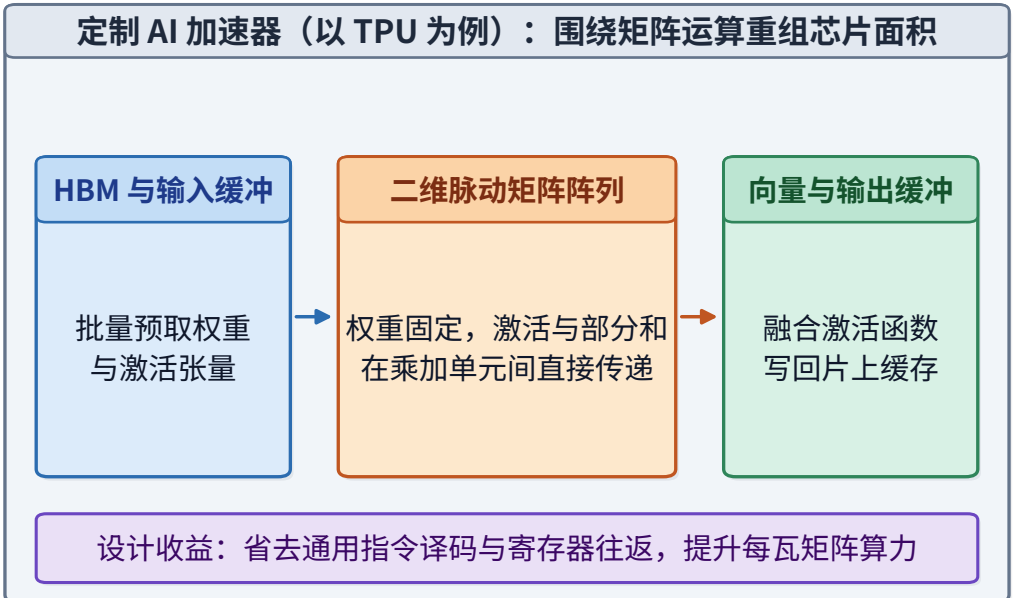
定制 AI 加速器（以 TPU 为例）：围绕矩阵运算重组芯片面积
HBM 与输入缓冲
批量预取权重
与激活张量
二维脉动矩阵阵列
权重固定，激活与部分和
在乘加单元间直接传递
向量与输出缓冲
融合激活函数
写回片上缓存
设计收益：省去通用指令译码与寄存器往返，提升每瓦矩阵算力