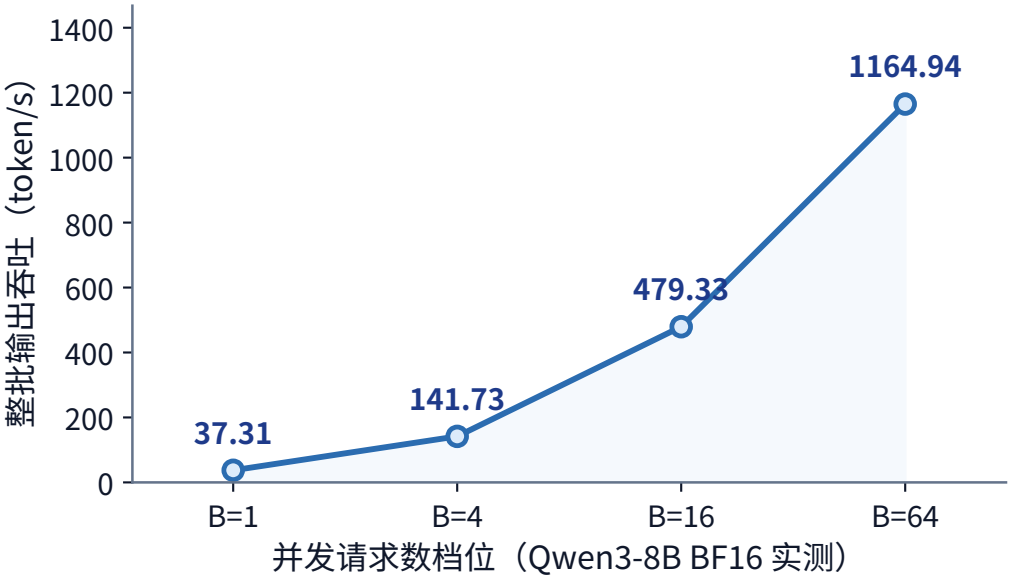
1400
1200
1000
800
600
400
200
0
整批输出吞吐（token/s）
37.31
141.73
479.33
1164.94
B=1
B=4
B=16
B=64
并发请求数档位（Qwen3-8B BF16 实测）