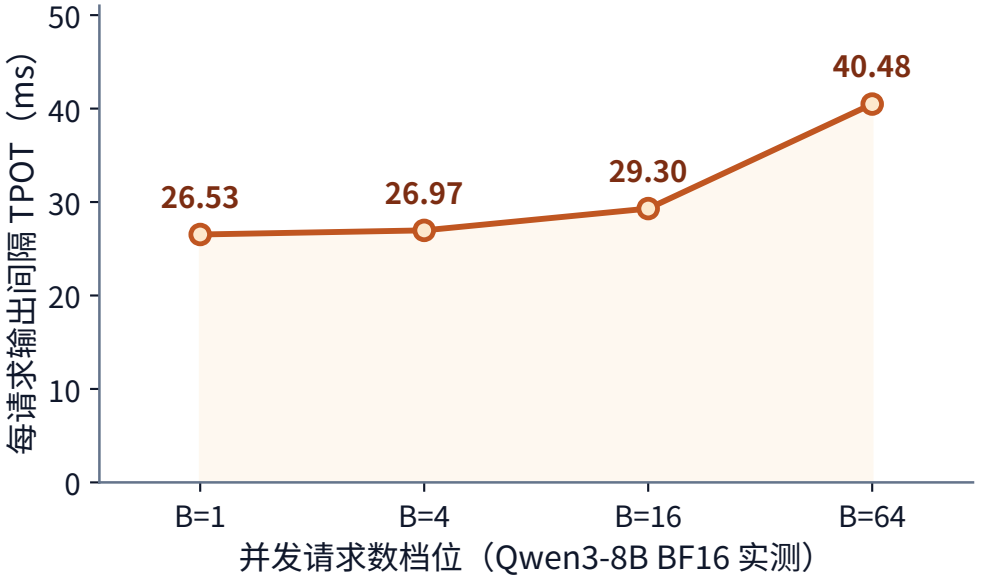
每请求输出间隔 TPOT（ms）
50
40
30
20
10
0
26.53
26.97
29.30
40.48
B=1
B=4
B=16
B=64
并发请求数档位（Qwen3-8B BF16 实测）