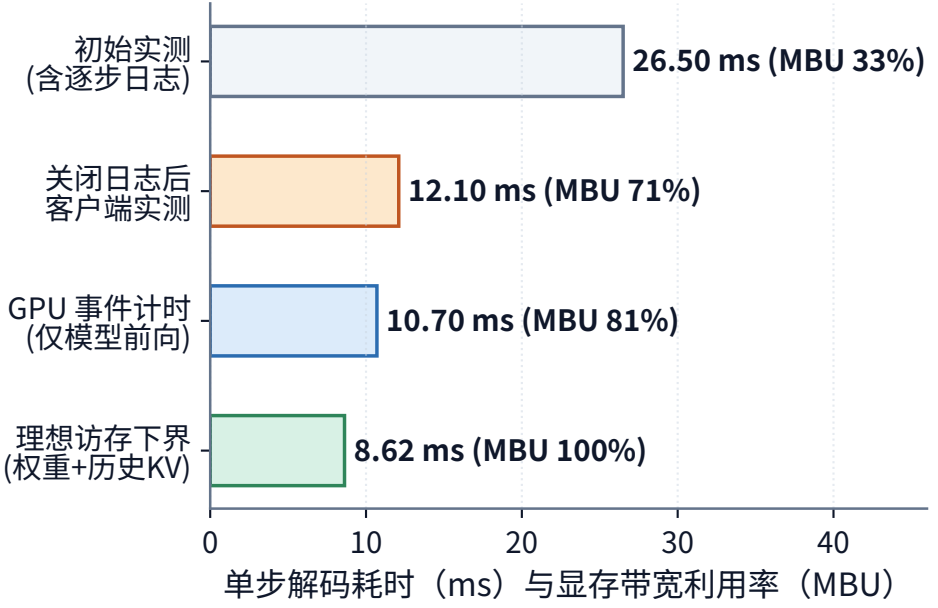
初始实测
(含逐步日志)
26.50 ms (MBU 33%)
关闭日志后
客户端实测
12.10 ms (MBU 71%)
GPU 事件计时
(仅模型前向)
10.70 ms (MBU 81%)
理想访存下界
(权重+历史KV)
8.62 ms (MBU 100%)
0
10
20
30
40
单步解码耗时（ms）与显存带宽利用率（MBU）