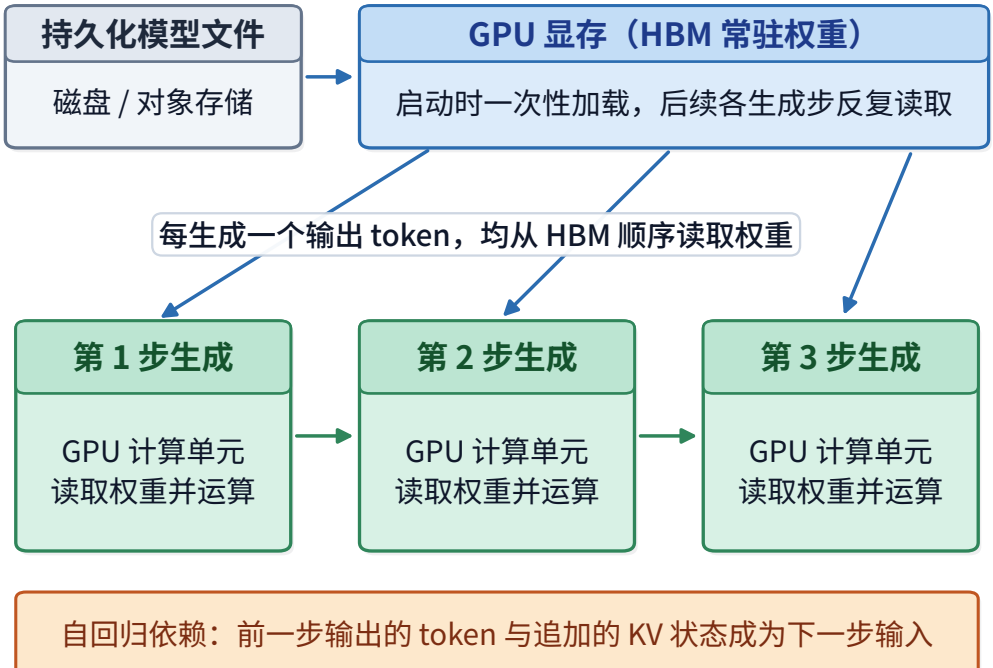
持久化模型文件
磁盘 / 对象存储
GPU 显存（HBM 常驻权重）
启动时一次性加载，后续各生成步反复读取
每生成一个输出 token，均从 HBM 顺序读取权重
第 1 步生成
GPU 计算单元
读取权重并运算
第 2 步生成
GPU 计算单元
读取权重并运算
第 3 步生成
GPU 计算单元
读取权重并运算
自回归依赖：前一步输出的 token 与追加的 KV 状态成为下一步输入