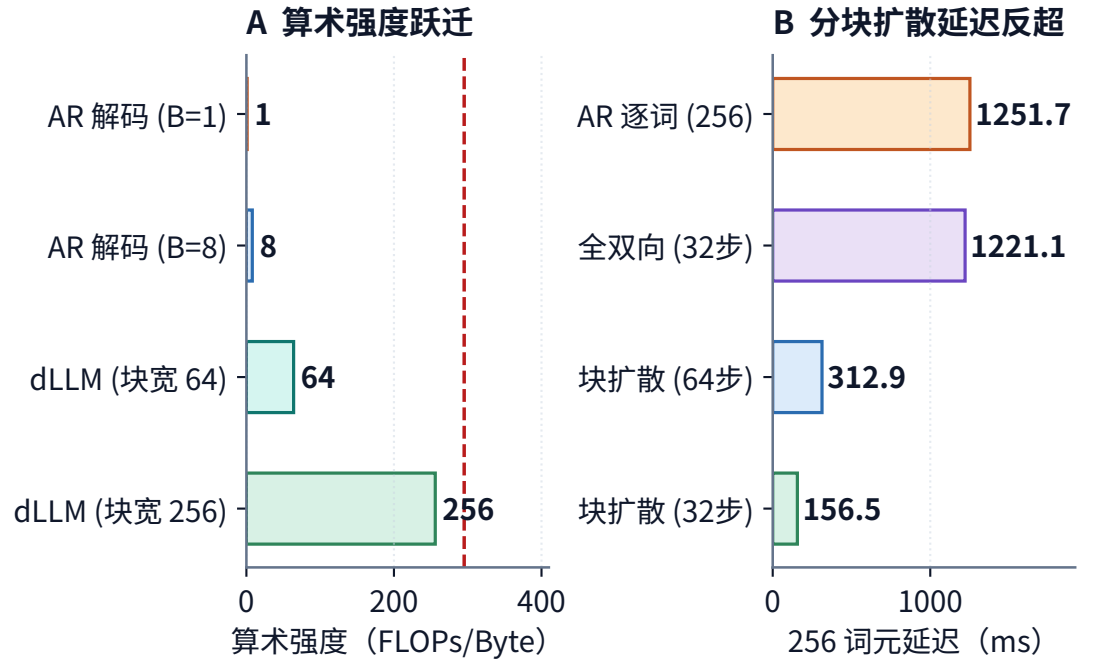
A 算术强度跃迁
AR 解码 (B=1)
1
AR 解码 (B=8)
8
dLLM (块宽 64)
64
dLLM (块宽 256)
256
0
200
400
算术强度（FLOPs/Byte）
B 分块扩散延迟反超
AR 逐词 (256)
1251.7
全双向 (32步)
1221.1
块扩散 (64步)
312.9
块扩散 (32步)
156.5
0
1000
256 词元延迟（ms）