A 字节潜空间 Transformer（BLT）：条件熵动态分块

1 局部字节编码

跨字节交叉注意
免除大词表查找

2 熵阈值切块

超阈值处切边界
常见词干合长块

3 全局潜空间层

按块执行变换
算力缩减 g_B 倍

自适应算力分配：低熵片段合并省算力，高熵突变处按字节精细推理

B 变长 Patch 对算子分块与多语言服务的影响

Ragged 变长算子

同批块数随文本熵波动
需变长偏移注意力内核

消除词表头与多语言膨胀

省去大词表输出头带宽
多语言与二进制压缩一致

主干计算缩减：全局层运算量降至字节基线的 1/g_B（块长 4.5~8.0）