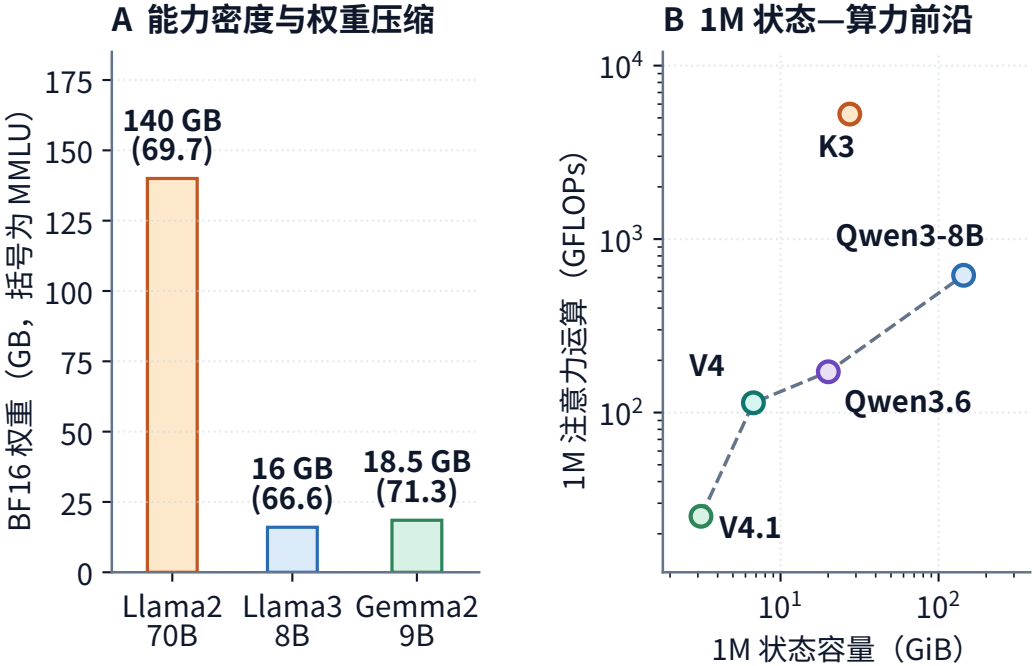
A 能力密度与权重压缩
BF16 权重（GB，括号为 MMLU）
175
150
125
100
75
50
25
0
140 GB
(69.7)
16 GB
(66.6)
18.5 GB
(71.3)
Llama2
70B
Llama3
8B
Gemma2
9B
B 1M 状态—算力前沿
1M 注意力运算（GFLOPs）
10^4
10^3
10^2
K3
Qwen3-8B
V4
Qwen3.6
V4.1
10^1
10^2
1M 状态容量（GiB）