A 原生稀疏注意力（NSA vs. MoBA）：硬件分块对齐

DeepSeek NSA 三分支

1 压缩分支：粗粒度块摘要
2 选择分支：选重要历史块
3 滑动窗口：保留局部连续

Kimi MoBA 无参数块路由

按 64/128 token 整块切分
块均值内积完成 Top-k 路由
零额外可训练门控参数开销

分块对齐红利：64 词元分块契合 Tensor Core 块并供 GQA 共享

B ECHO（OSDI '26）：复用压缩分支得分的跨层无损预取

1 压缩打分

第 l 层算块得分
识别下层热点块

2 异步预取

PCIe 提前搬运
与第 l 层重叠

3 无损计算

抵达 l+1 层 HBM
零精度损失计算

解耦机制：压缩摘要常驻 HBM 充当索引，原始 KV 块按需无损调入