A 多模态扩散算力与 3D 因果 VAE 特征缓存克隆尖峰

Qwen-Image-2512 (20B)

100 次调用 · 7830.4 TFLOPs
占全链路算力 99.85%

FLUX.2-klein-4B (蒸馏)

4 步单分支 · 139.3 TFLOPs
算力降 56.2× · VAE 248 MiB

3D 因果 VAE 解码：算力仅占 0.15% (11.7 TFLOPs)，主导显存尖峰

30 槽位缓存 1.125 GiB 经 .clone() 翻倍至 2.250 GiB + 1.0 GiB 激活

B 注意力掩码拓扑与 KV 缓存跨步不变性边界（AR vs dLLM）

1 自回归因果掩码（AR）：下三角隔离未来，历史 KV 严格不变

单步输入 $m = 1$（矩阵乘退化为向量乘，受限于 HBM 访存带宽）

2 全序列双向去噪（朴素 dLLM）：双向互看，揭开词元改变全局状态

历史 KV 无法跨去噪步冻结复用，每步须重算全序列激活

3 分块半自回归扩散（Block dLLM）：块间因果掩码 + 块内双向去噪

冻结提示词与历史块 KV；块内 $m = B_{\text{blk}}$ 并行重算（转向算力受限）