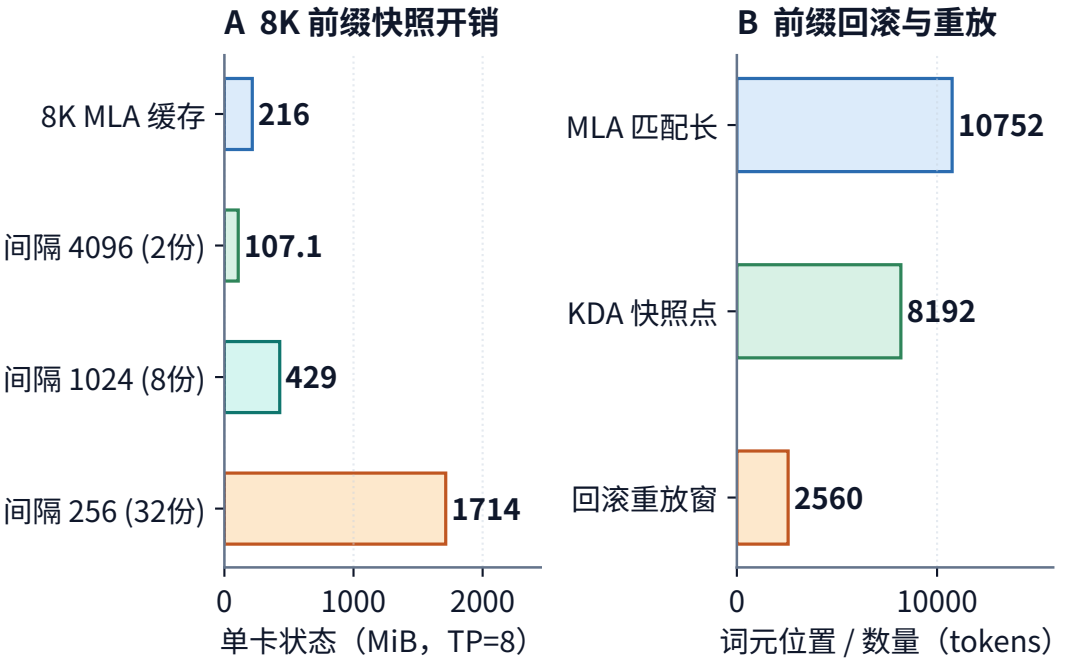
A 8K 前缀快照开销
8K MLA 缓存
216
间隔 4096 (2份)
107.1
间隔 1024 (8份)
429
间隔 256 (32份)
1714
0
1000
2000
单卡状态（MiB，TP=8）
B 前缀回滚与重放
MLA 匹配长
10752
KDA 快照点
8192
回滚重放窗
2560
0
10000
词元位置 / 数量（tokens）