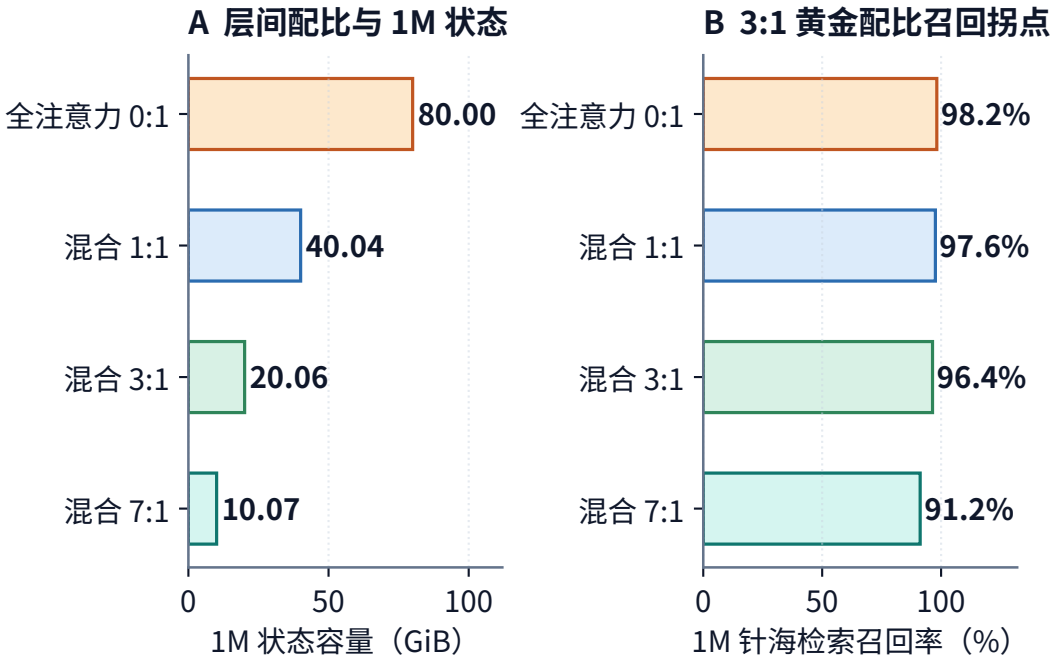
A 层间配比与 1M 状态
全注意力 0:1
80.00
混合 1:1
40.04
混合 3:1
20.06
混合 7:1
10.07
0
50
100
1M 状态容量（GiB）
B 3:1 黄金配比召回拐点
全注意力 0:1
98.2%
混合 1:1
97.6%
混合 3:1
96.4%
混合 7:1
91.2%
0
50
100
1M 针海检索召回率（%）