A MLA 展开路径 vs. 矩阵吸收紧凑路径的张量收缩变换

展开路径（Prefill 路径）

c_KV 先经 W_UK/W_UV 展开
单头宽 128+64，V 宽 128
适合长提示词单次展开复用

矩阵吸收路径（Decode 路径）

W_UK 吸收进查询侧 q_abs
W_UV 移至注意力汇总之后
直接与潜变量 C_KV 做点积

恒等本质：(q W_UQ)(c_KV W_UK)^T = (q W_UQ W_UK^T) c_KV^T

B DeepSeek-V3 (128头) 单词元缓存读取与计算代价对比

HBM 读取压缩

展开 65,536 B/词
吸收 1,152 B/词

吸收投影开销

128x128x512 变换
仅当前 m=1 执行

算术强度跃升

128头共享潜变量
达 241.8 FLOPs/B

向后桥接（第 24 章 FlashMLA）：[512+64] 头维跑出 3,000 GB/s 带宽