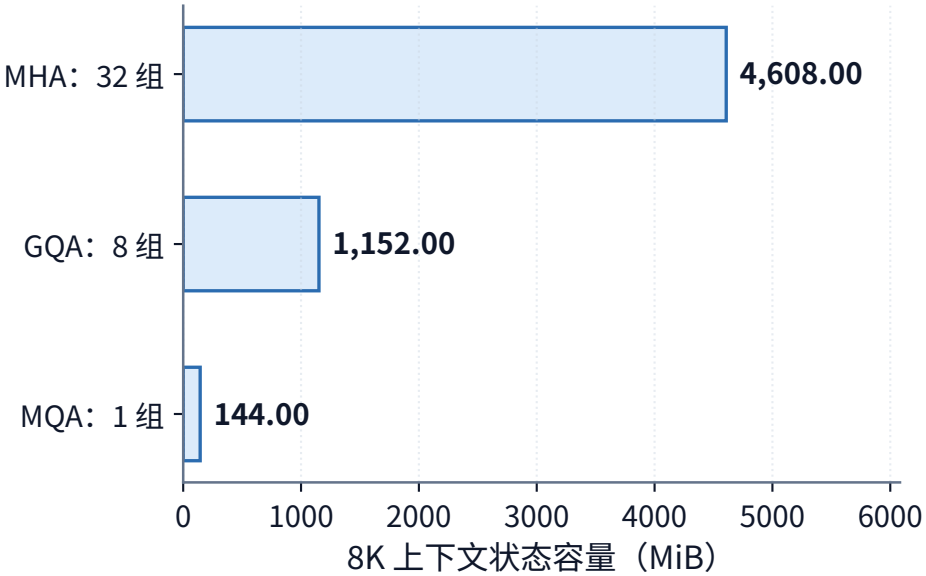
MHA：32 组
4,608.00
GQA：8 组
1,152.00
MQA：1 组
144.00
0
1000
2000
3000
4000
5000
6000
8K 上下文状态容量（MiB）