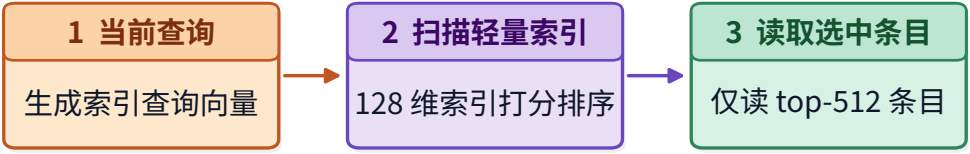## 压缩稀疏注意力（CSA）：先形成块压缩条目，再由索引器筛选 top-k