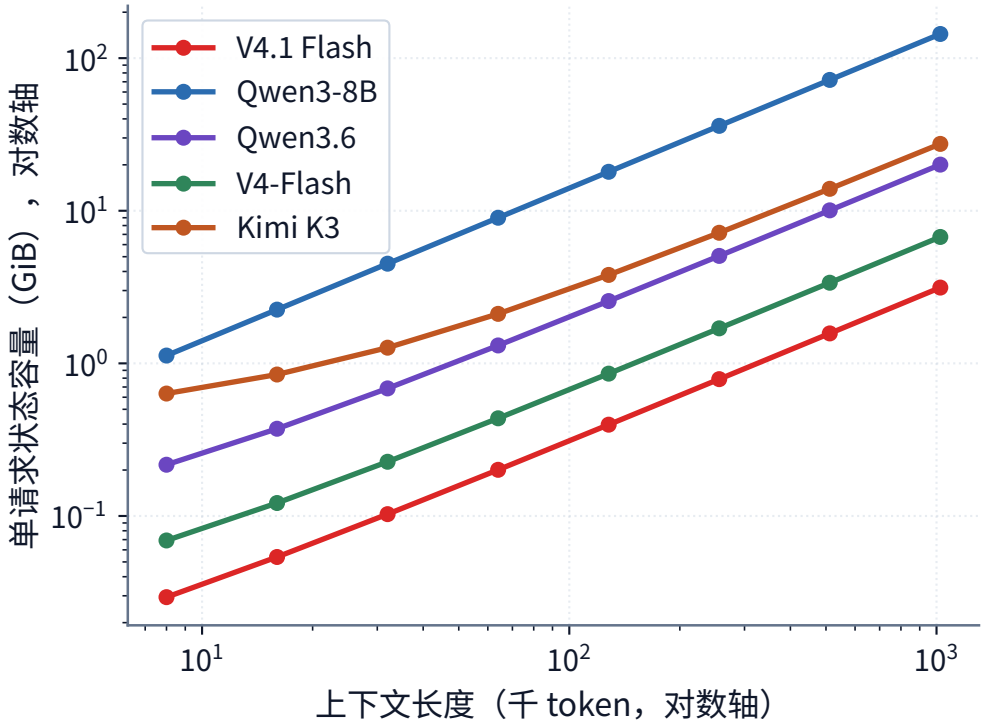
V4.1 Flash
Qwen3-8B
Qwen3.6
V4-Flash
Kimi K3
单请求状态容量（GiB），对数轴
$10^2$
$10^1$
$10^0$
$10^{-1}$
$10^1$
$10^2$
$10^3$
上下文长度（千 token，对数轴）