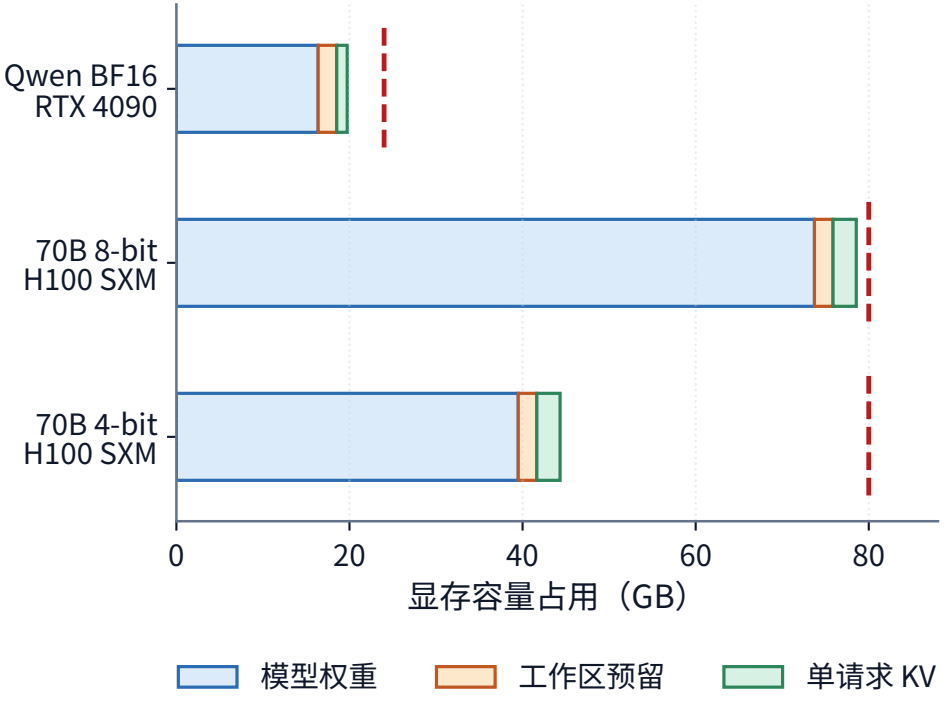
Qwen BF16
RTX 4090
70B 8-bit
H100 SXM
70B 4-bit
H100 SXM
0
20
40
60
80
显存容量占用（GB）
模型权重
工作区预留
单请求 KV