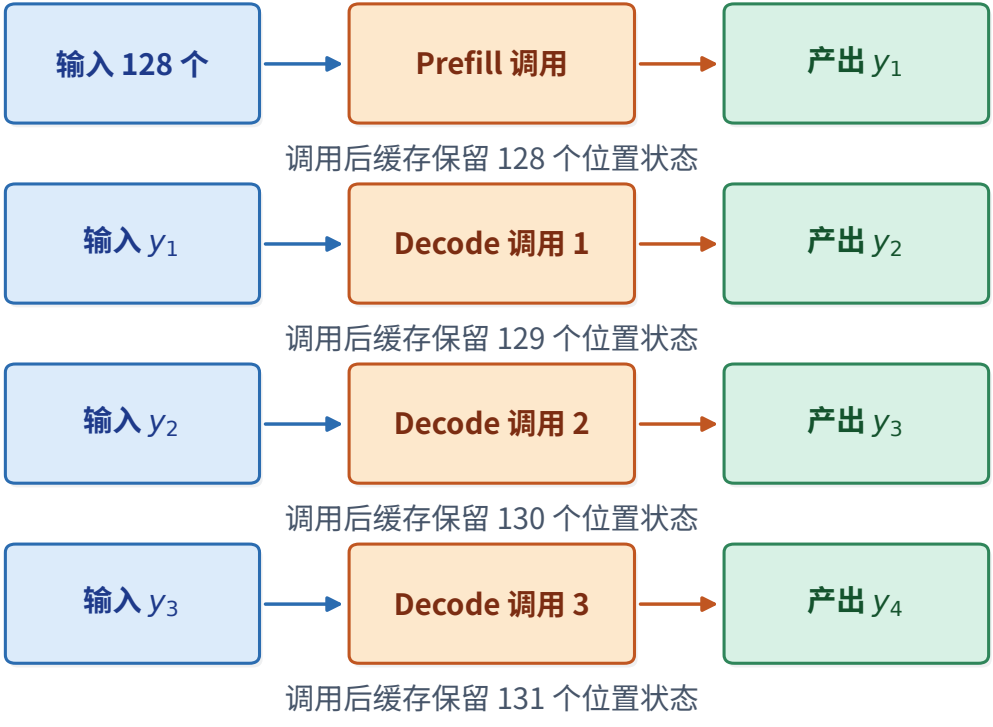输入 128 个 token、生成返回 4 个输出 token 的调用链