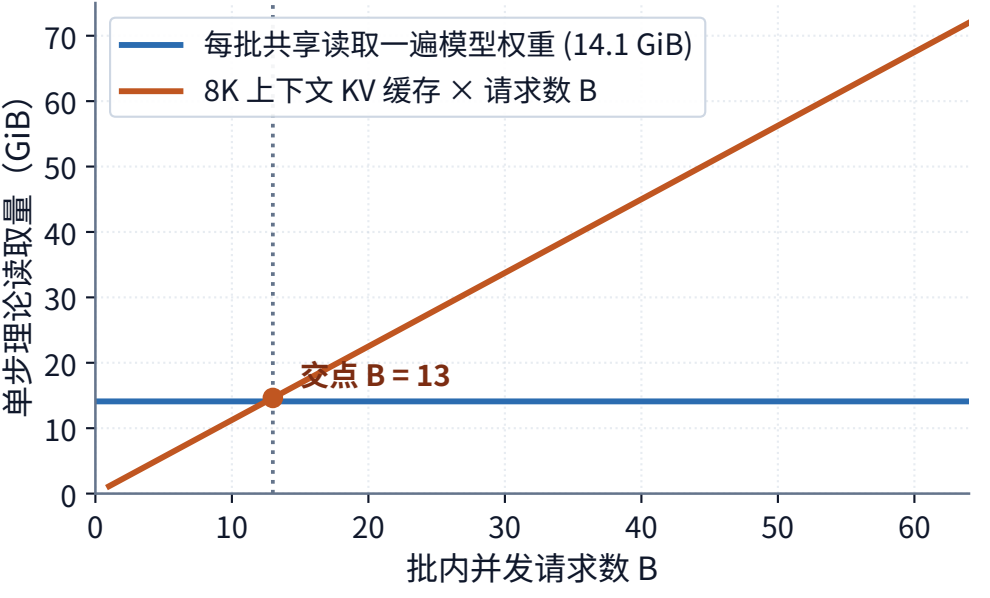
每批共享读取一遍模型权重 (14.1 GiB)
8K 上下文 KV 缓存 × 请求数 B
交点 B = 13
单步理论读取量（GiB）
批内并发请求数 B
0
10
20
30
40
50
60
70