## 自回归解码：每一步追加 1 个新 token，并重读全部已有上下文

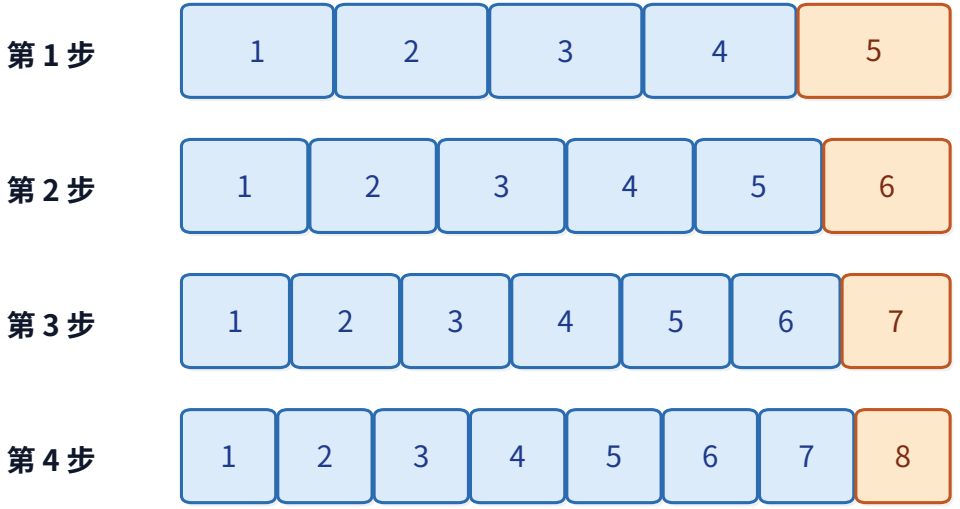


蓝色格：从缓存重读的历史位置 · 橙色格：本步新生成并追加的位置