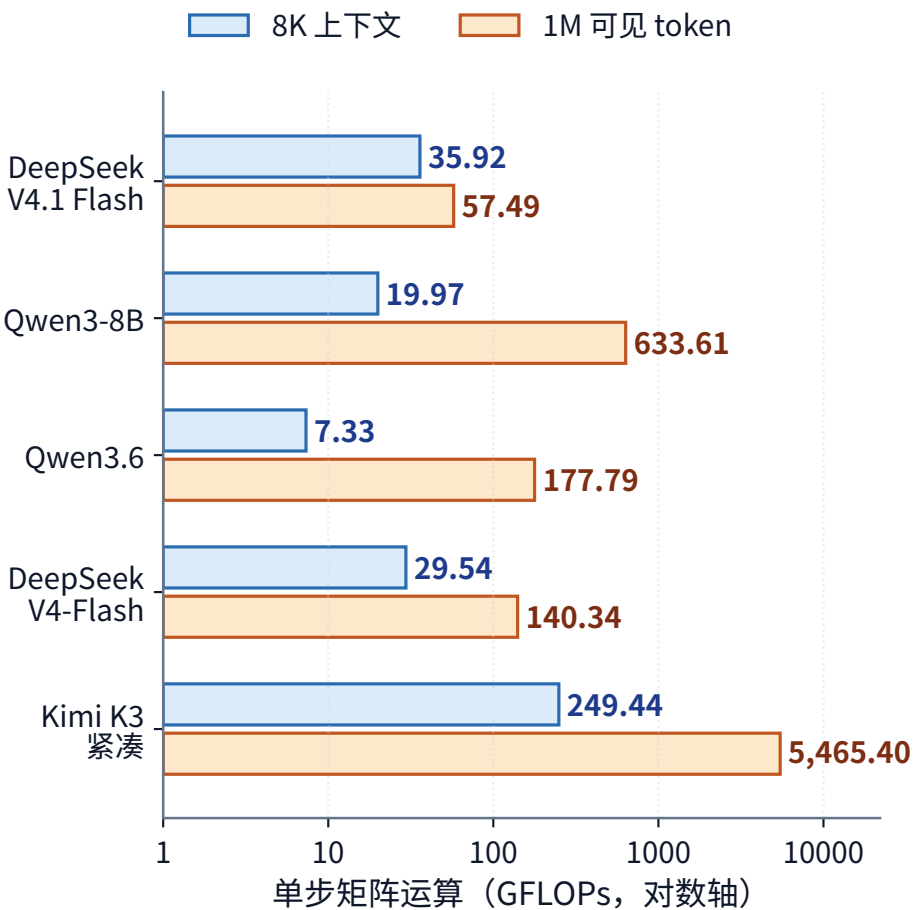
8K 上下文
1M 可见 token
DeepSeek V4.1 Flash
35.92
57.49
Qwen3-8B
19.97
633.61
Qwen3.6
7.33
177.79
DeepSeek V4-Flash
29.54
140.34
Kimi K3 紧凑
249.44
5,465.40
1
10
100
1000
10000
单步矩阵运算（GFLOPs，对数轴）