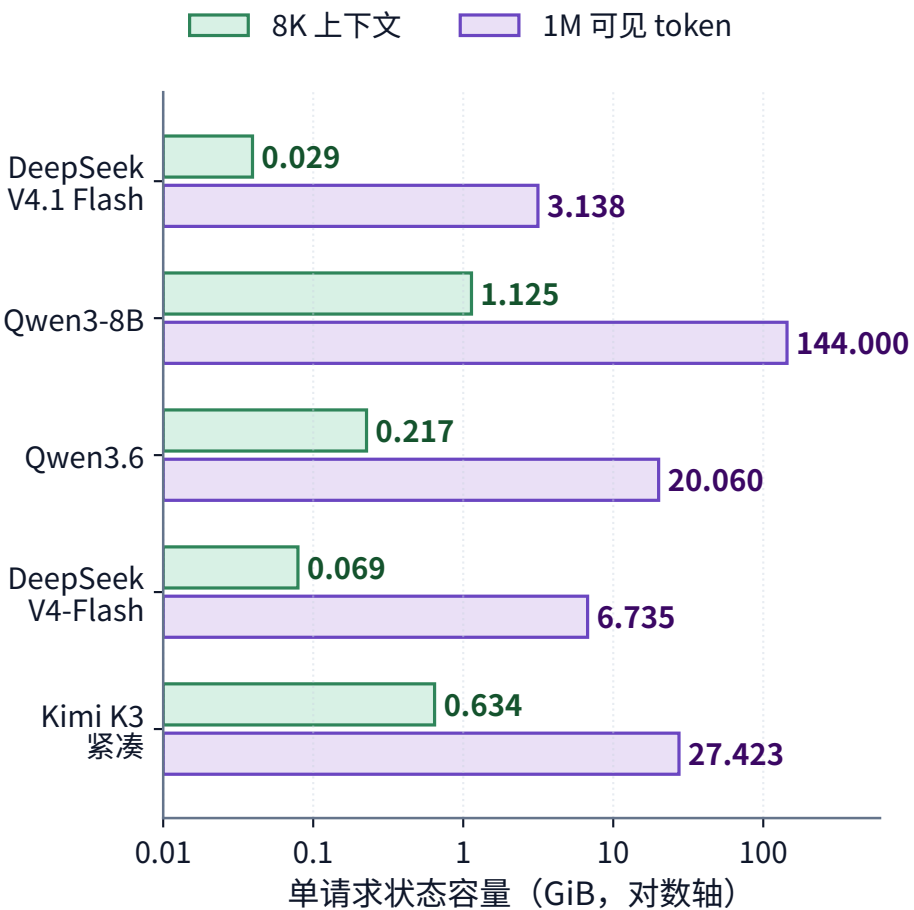
8K 上下文
1M 可见 token
DeepSeek V4.1 Flash
0.029
3.138
Qwen3-8B
1.125
144.000
Qwen3.6
0.217
20.060
DeepSeek V4-Flash
0.069
6.735
Kimi K3 紧凑
0.634
27.423
0.01
0.1
1
10
100
单请求状态容量（GiB，对数轴）