线性递推注意力：上下文增长，固定大小状态矩阵原地更新

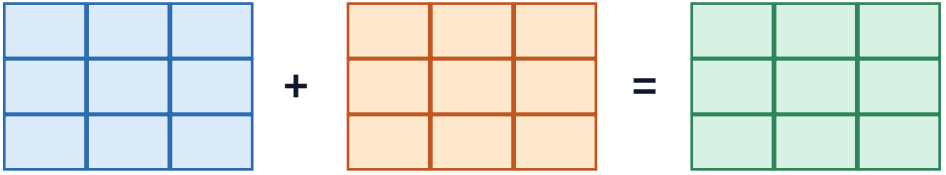

旧状态 S_{t-1}　　新外积 $k_t v_t^\top$　　新状态 S_t

当前查询读取固定状态矩阵：$o_t = q_t^\top S_t$（状态体积与长度无关）