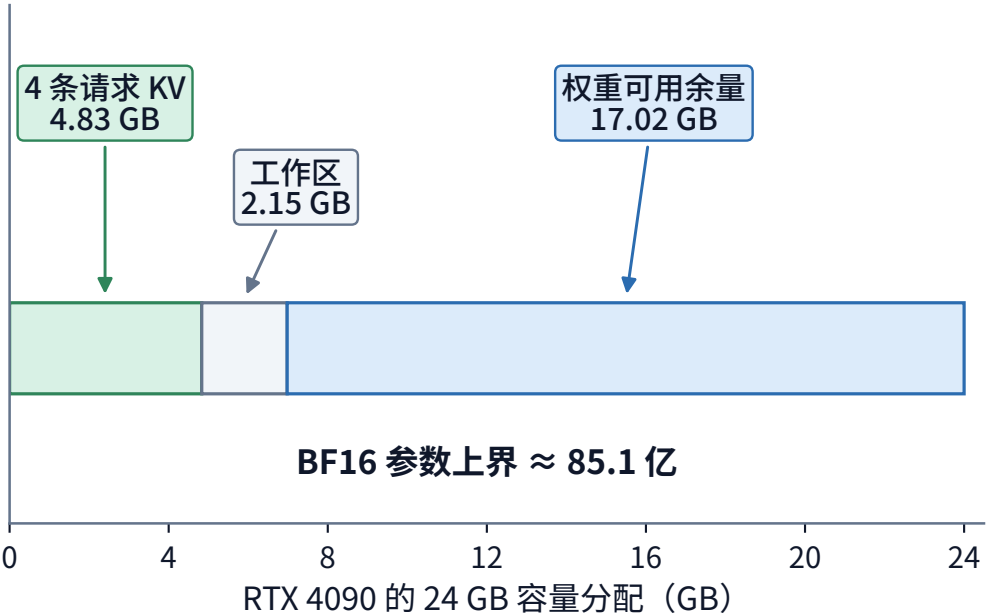
4 条请求 KV
4.83 GB
工作区
2.15 GB
权重可用余量
17.02 GB
BF16 参数上界 ≈ 85.1 亿
0
4
8
12
16
20
24
RTX 4090 的 24 GB 容量分配（GB）