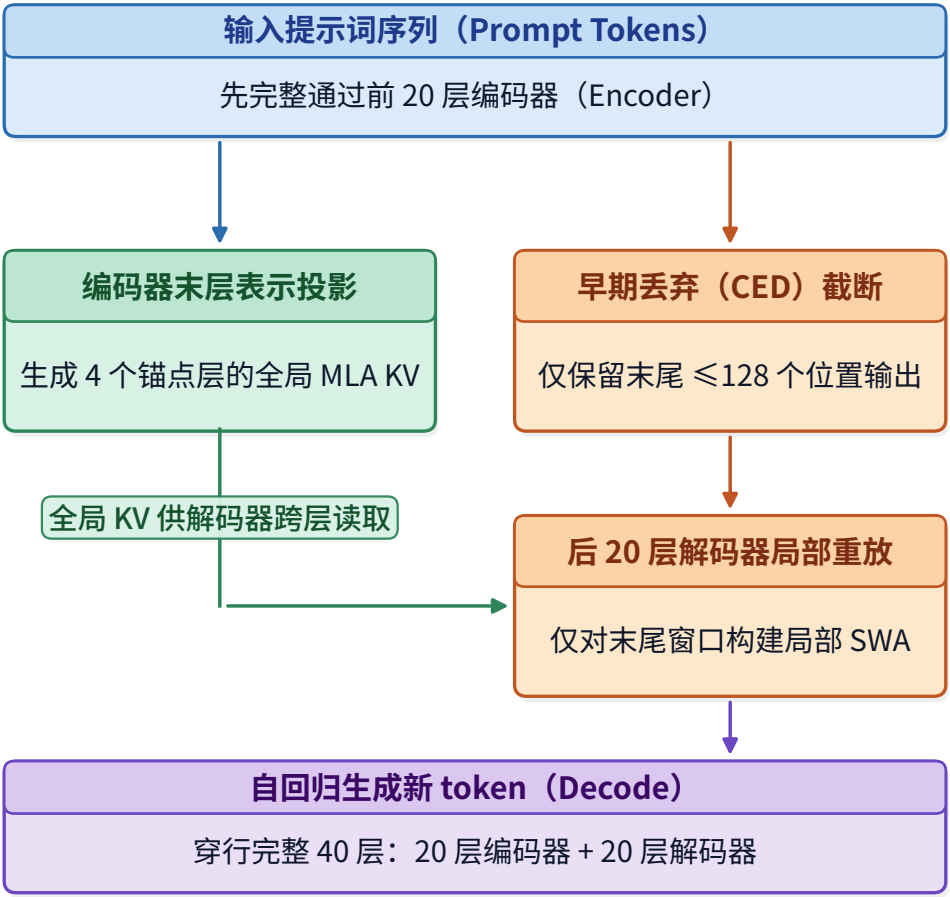
输入提示词序列（Prompt Tokens）
先完整通过前 20 层编码器（Encoder）
编码器末层表示投影
生成 4 个锚点层的全局 MLA KV
早期丢弃（CED）截断
仅保留末尾 ≤128 个位置输出
全局 KV 供解码器跨层读取
后 20 层解码器局部重放
仅对末尾窗口构建局部 SWA
自回归生成新 token（Decode）
穿行完整 40 层：20 层编码器 + 20 层解码器