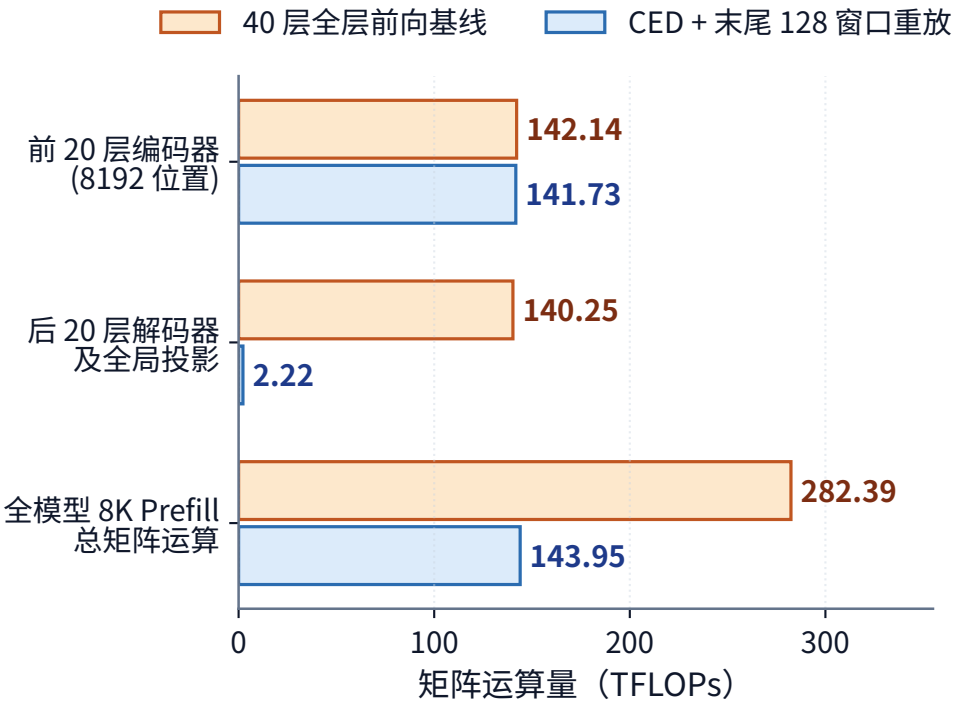
40 层全层前向基线
CED + 末尾 128 窗口重放
前 20 层编码器
(8192 位置)
142.14
141.73
后 20 层解码器
及全局投影
140.25
2.22
全模型 8K Prefill
总矩阵运算
282.39
143.95
0
100
200
300
矩阵运算量（TFLOPs）