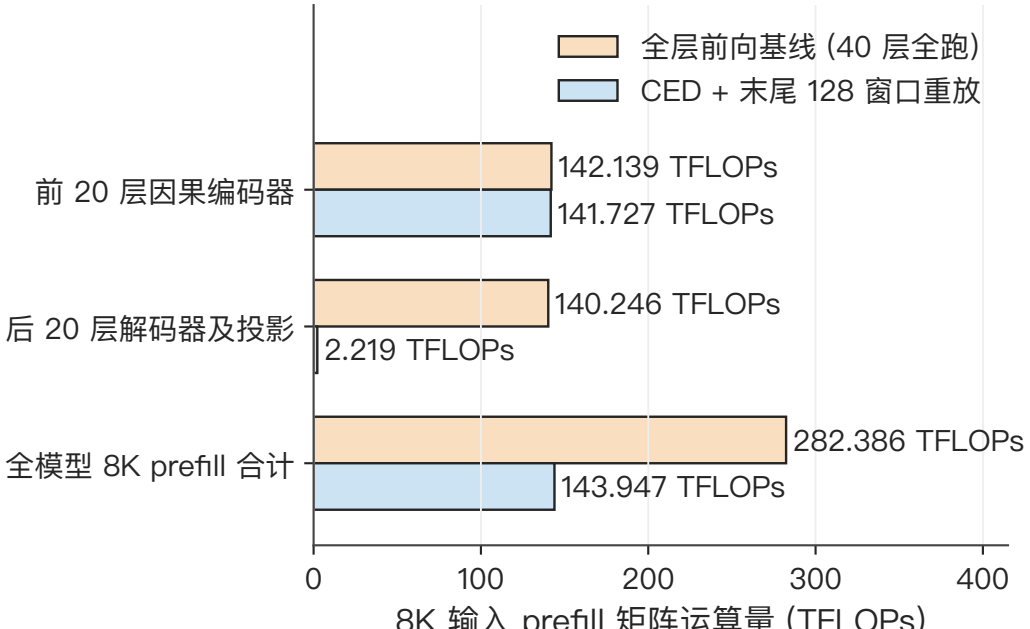
全层前向基线 (40 层全跑)
CED + 末尾 128 窗口重放
前 20 层因果编码器
142.139 TFLOPs
141.727 TFLOPs
后 20 层解码器及投影
140.246 TFLOPs
2.219 TFLOPs
全模型 8K prefill 合计
282.386 TFLOPs
143.947 TFLOPs
0
100
200
300
400
8K 输入 prefill 矩阵运算量 (TFLOPs)