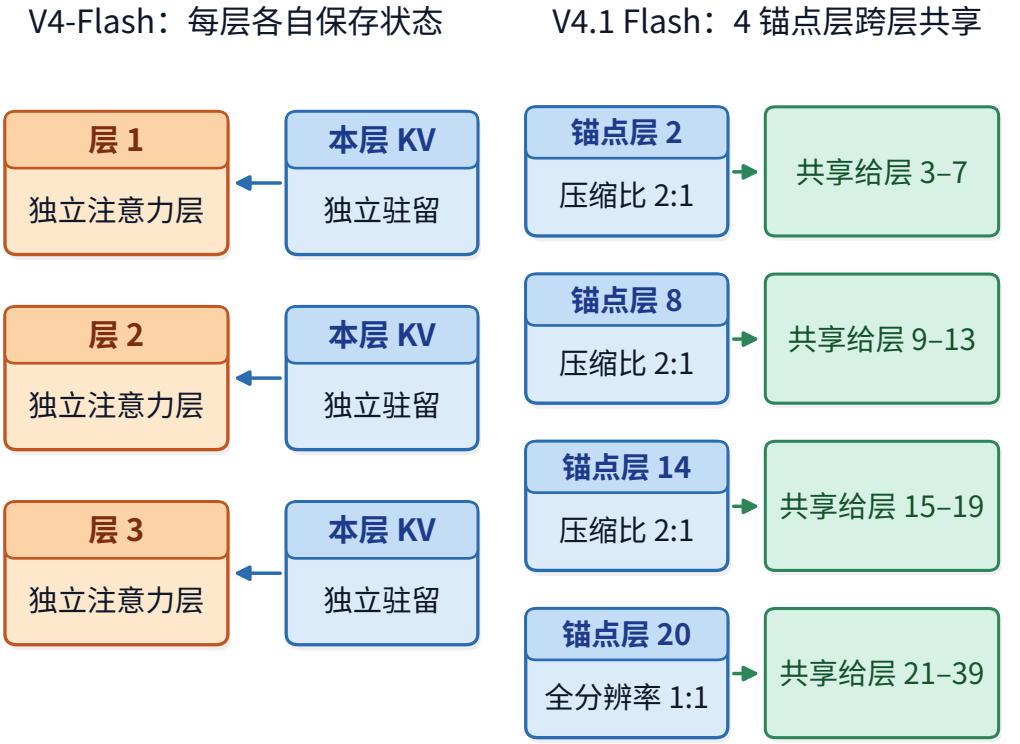
V4-Flash：每层各自保存状态
层 1
独立注意力层
本层 KV
独立驻留
层 2
独立注意力层
本层 KV
独立驻留
层 3
独立注意力层
本层 KV
独立驻留
V4.1 Flash：4 锚点层跨层共享
锚点层 2
压缩比 2:1
共享给层 3–7
锚点层 8
压缩比 2:1
共享给层 9–13
锚点层 14
压缩比 2:1
共享给层 15–19
锚点层 20
全分辨率 1:1
共享给层 21–39
各层仍保留独立查询 Q 与 128-token 局部 SWA
层编号从 0 开始；全局状态合计压缩至 890 B/token