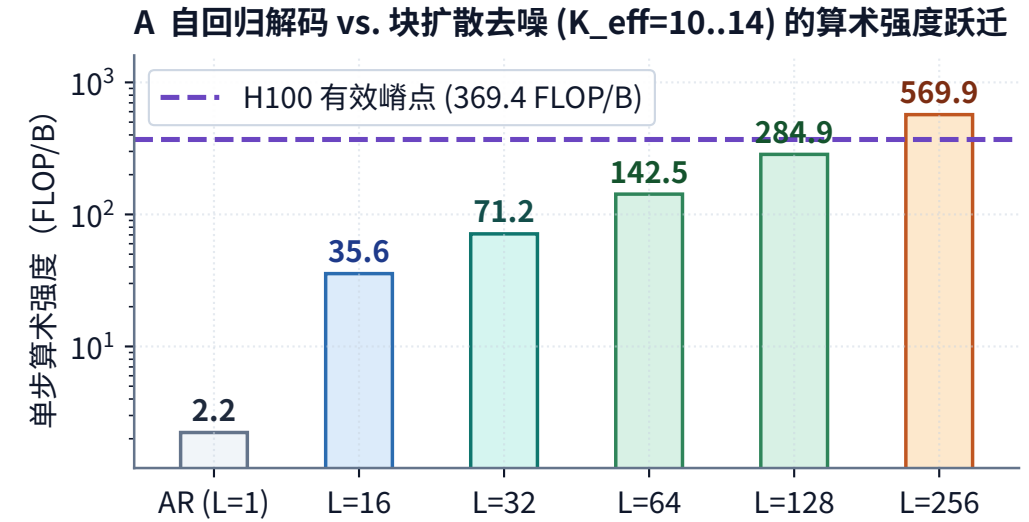
A 自回归解码 vs. 块扩散去噪 (K_eff=10..14) 的算术强度跃迁
单步算术强度（FLOP/B）
10^3
10^2
10^1
H100 有效嵴点 (369.4 FLOP/B)
2.2
35.6
71.2
142.5
284.9
569.9
AR (L=1)
L=16
L=32
L=64
L=128
L=256

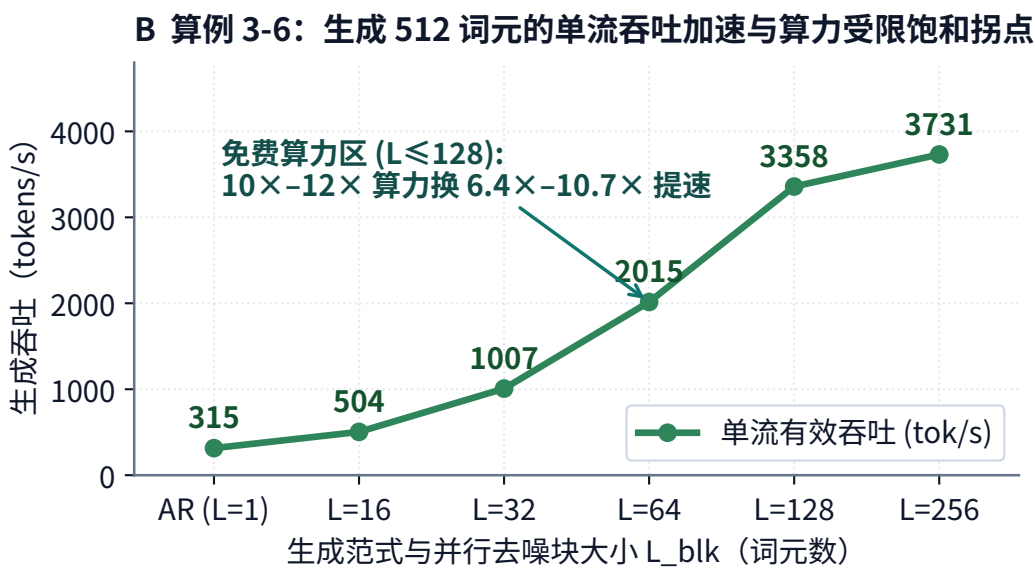
B 算例 3-6：生成 512 词元的单流吞吐加速与算力受限饱和拐点
生成吞吐（tokens/s）
4000
3000
2000
1000
0
免费算力区 (L≤128):
10×–12× 算力换 6.4×–10.7× 提速
315
504
1007
2015
3358
3731
单流有效吞吐 (tok/s)
AR (L=1)
L=16
L=32
L=64
L=128
L=256
生成范式与并行去噪块大小 L_blk（词元数）