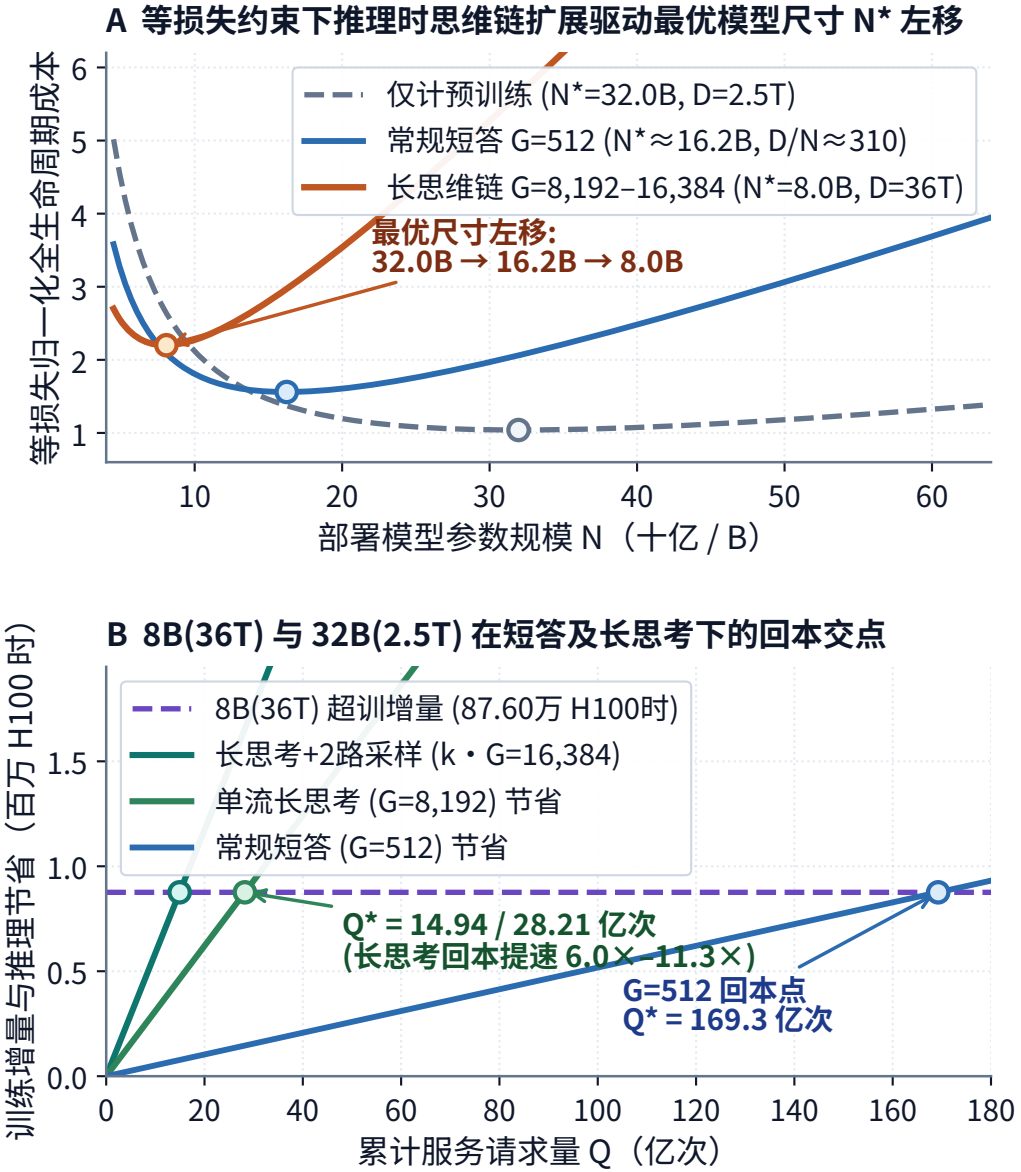
A 等损失约束下推理时思维链扩展驱动最优模型尺寸 N* 左移
等损失归一化全生命周期成本
仅计预训练 (N*=32.0B, D=2.5T)
常规短答 G=512 (N*≈16.2B, D/N≈310)
长思维链 G=8,192–16,384 (N*=8.0B, D=36T)
最优尺寸左移:
32.0B → 16.2B → 8.0B
部署模型参数规模 N（十亿 / B）
B 8B(36T) 与 32B(2.5T) 在短答及长思考下的回本交点
训练增量与推理节省（百万 H100 时）
8B(36T) 超训增量 (87.60万 H100时)
长思考+2路采样 (k・G=16,384)
单流长思考 (G=8,192) 节省
常规短答 (G=512) 节省
Q* = 14.94 / 28.21 亿次
(长思考回本提速 6.0×–11.3×)
G=512 回本点
Q* = 169.3 亿次
累计服务请求量 Q（亿次）