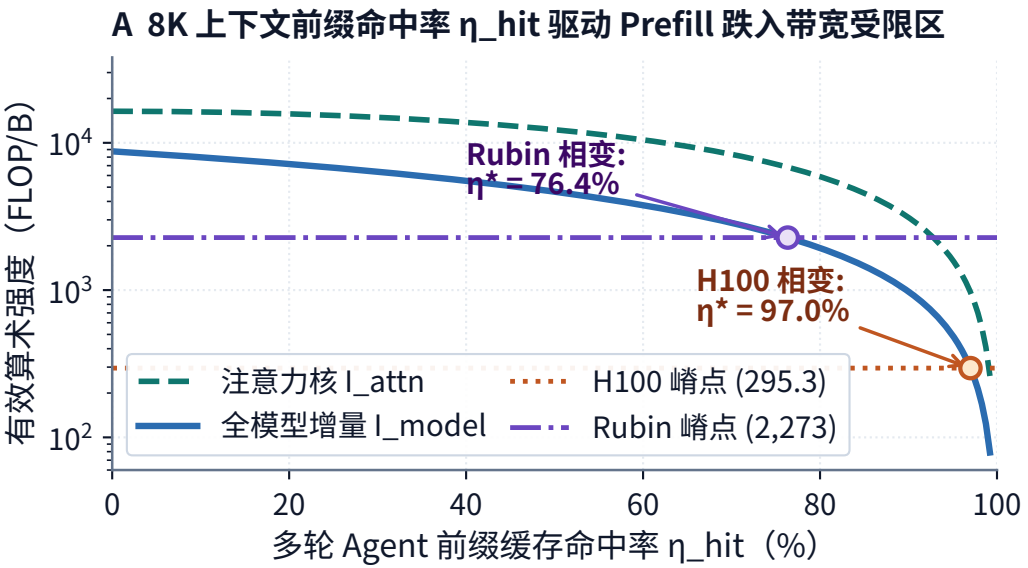
A 8K 上下文前缀命中率 η_hit 驱动 Prefill 跌入带宽受限区
有效算术强度（FLOP/B）
10^4
10^3
10^2
Rubin 相变:
η* = 76.4%
H100 相变:
η* = 97.0%
注意力核 I_attn
全模型增量 I_model
H100 嵴点 (295.3)
Rubin 嵴点 (2,273)
0
20
40
60
80
100
多轮 Agent 前缀缓存命中率 η_hit（%）

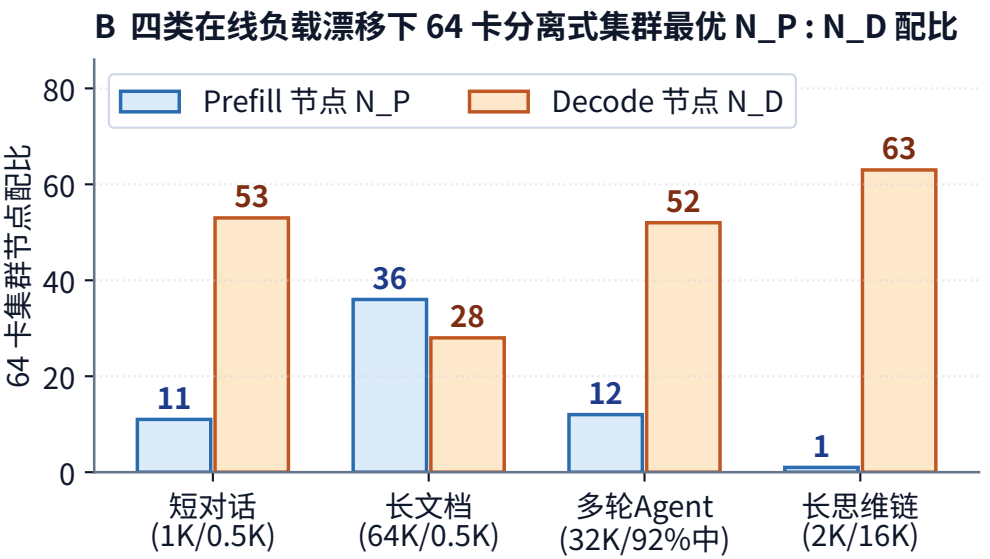
B 四类在线负载漂移下 64 卡分离式集群最优 N_P : N_D 配比
64 卡集群节点配比
Prefill 节点 N_P
Decode 节点 N_D
0
20
40
60
80
11
53
36
28
12
52
1
63
短对话
(1K/0.5K)
长文档
(64K/0.5K)
多轮Agent
(32K/92%中)
长思维链
(2K/16K)