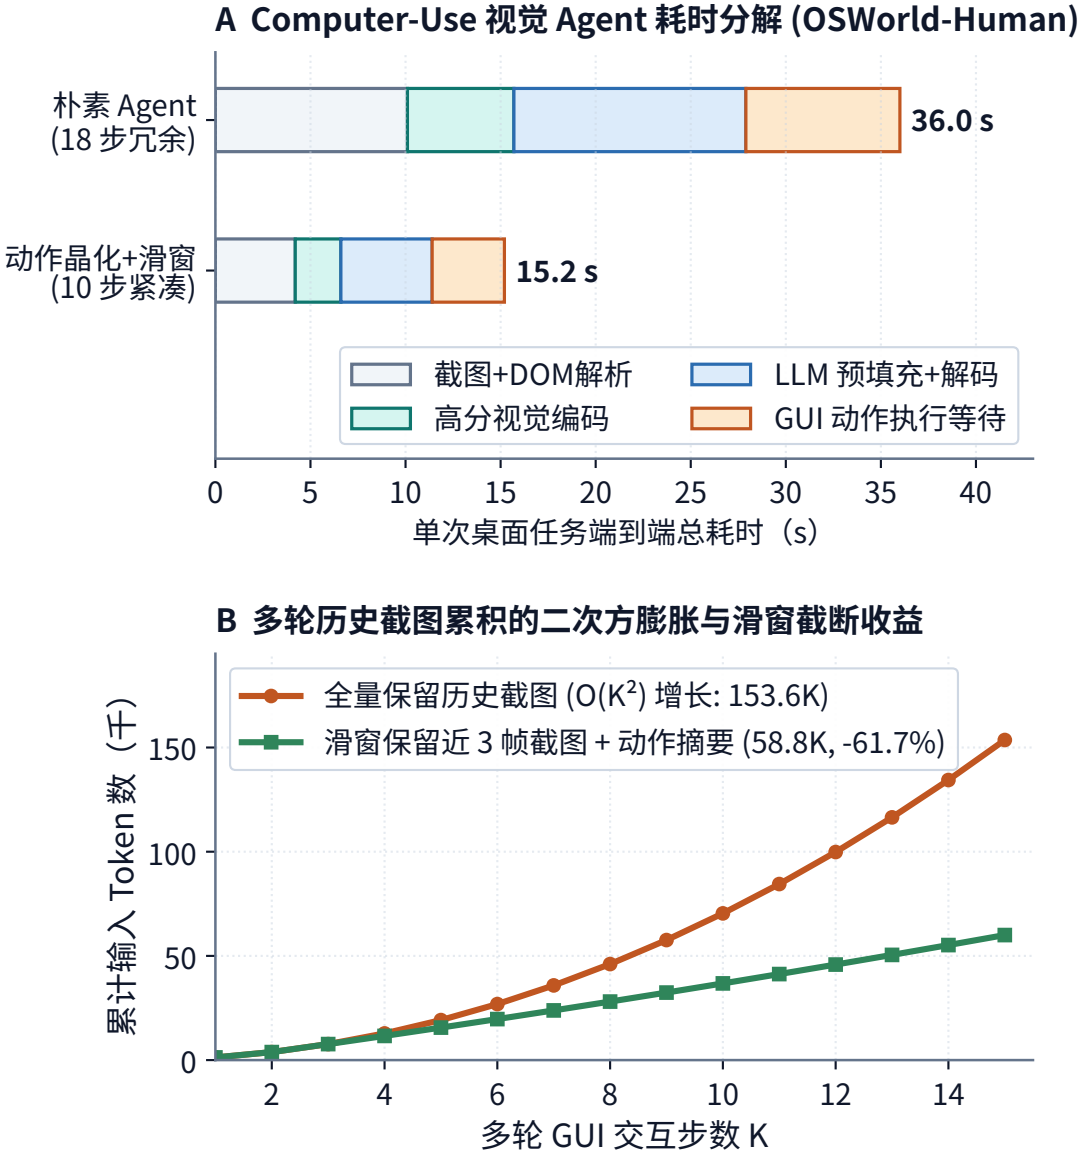
A Computer-Use 视觉 Agent 耗时分解 (OSWorld-Human)
朴素 Agent
(18 步冗余)
36.0 s
动作晶化+滑窗
(10 步紧凑)
15.2 s
截图+DOM解析
LLM 预填充+解码
高分视觉编码
GUI 动作执行等待
0
5
10
15
20
25
30
35
40
单次桌面任务端到端总耗时（s）
B 多轮历史截图累积的二次方膨胀与滑窗截断收益
全量保留历史截图 (O(K²) 增长: 153.6K)
滑窗保留近 3 帧截图 + 动作摘要 (58.8K, -61.7%)
累计输入 Token 数（千）
150
100
50
0
2
4
6
8
10
12
14
多轮 GUI 交互步数 K