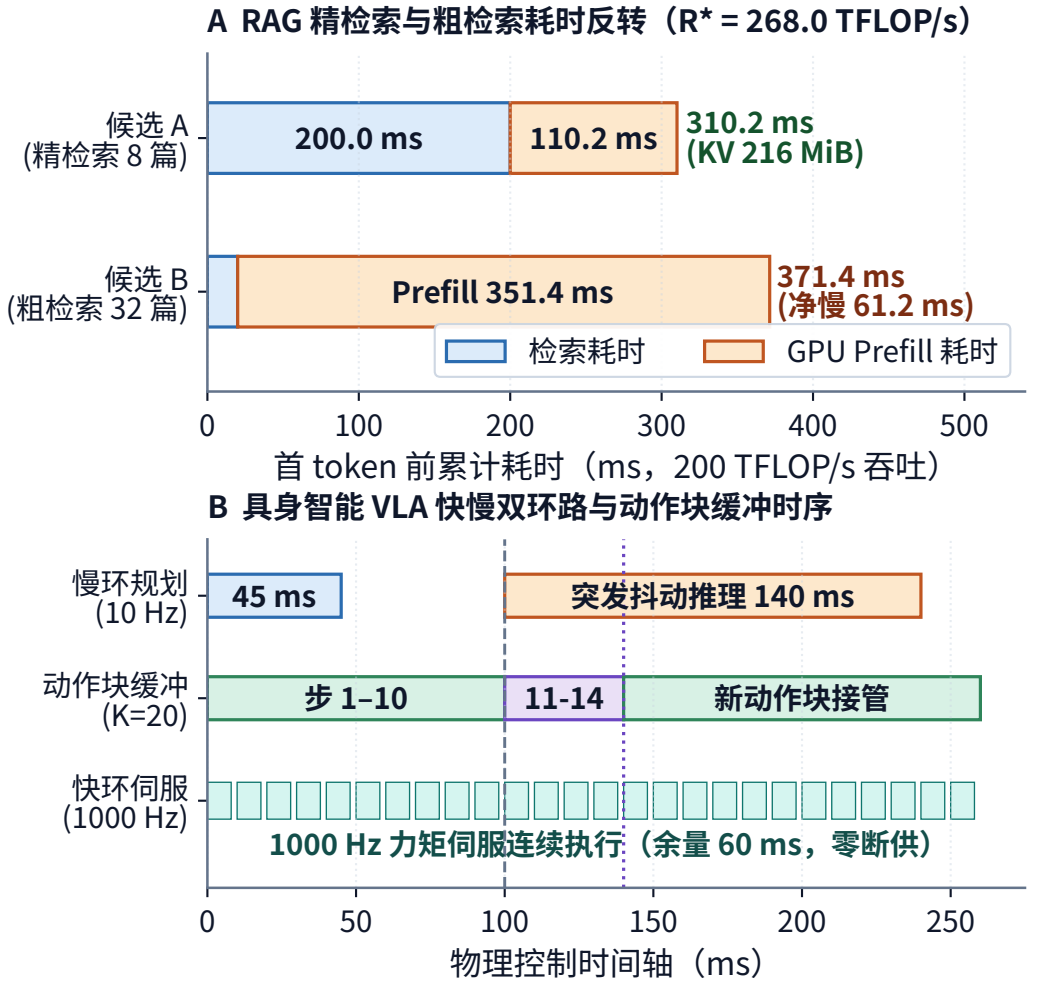
A RAG 精检索与粗检索耗时反转（R* = 268.0 TFLOP/s）
候选 A
(精检索 8 篇)
200.0 ms
110.2 ms
310.2 ms
(KV 216 MiB)
候选 B
(粗检索 32 篇)
Prefill 351.4 ms
371.4 ms
(净慢 61.2 ms)
检索耗时
GPU Prefill 耗时
0
100
200
300
400
500
首 token 前累计耗时（ms，200 TFLOP/s 吞吐）
B 具身智能 VLA 快慢双环路与动作块缓冲时序
慢环规划
(10 Hz)
45 ms
突发抖动推理 140 ms
动作块缓冲
(K=20)
步 1–10
11-14
新动作块接管
快环伺服
(1000 Hz)
1000 Hz 力矩伺服连续执行（余量 60 ms，零断供）
0
50
100
150
200
250
物理控制时间轴（ms）