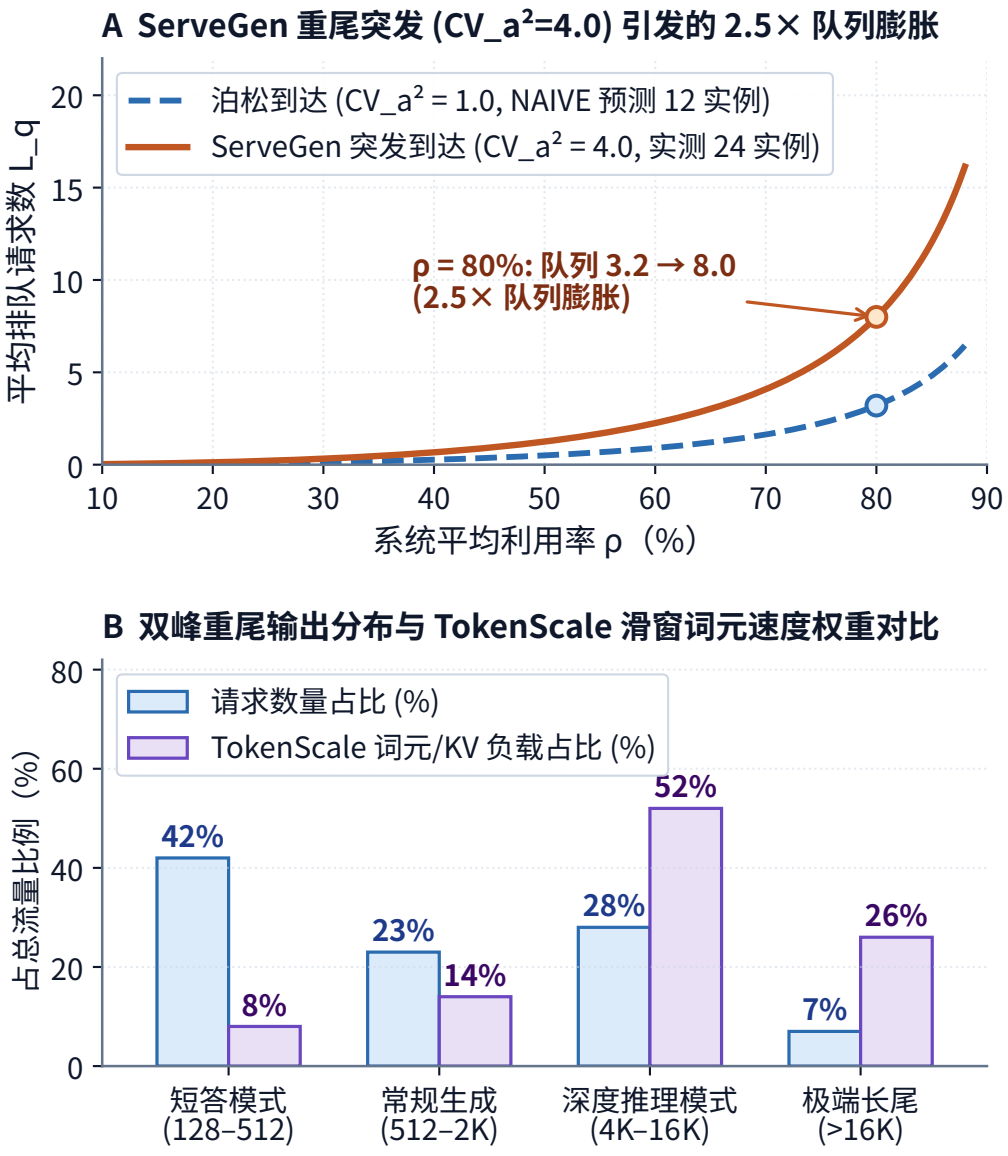
A ServeGen 重尾突发 (CV_a²=4.0) 引发的 2.5× 队列膨胀
泊松到达 (CV_a² = 1.0, NAIVE 预测 12 实例)
ServeGen 突发到达 (CV_a² = 4.0, 实测 24 实例)
ρ = 80%: 队列 3.2 → 8.0
(2.5× 队列膨胀)
平均排队请求数 L_q
系统平均利用率 ρ（%）
0
5
10
15
20
10
20
30
40
50
60
70
80
90
B 双峰重尾输出分布与 TokenScale 滑窗词元速度权重对比
请求数量占比 (%)
TokenScale 词元/KV 负载占比 (%)
占总流量比例（%）
0
20
40
60
80
42%
8%
23%
14%
28%
52%
7%
26%
短答模式
(128–512)
常规生成
(512–2K)
深度推理模式
(4K–16K)
极端长尾
(>16K)