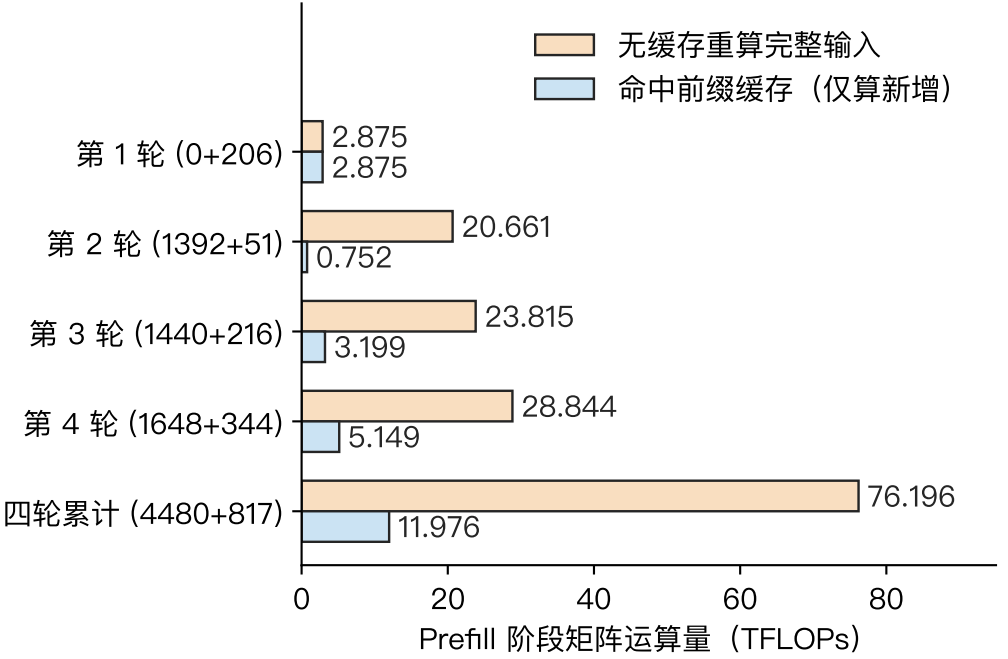
无缓存重算完整输入
命中前缀缓存（仅算新增）
第 1 轮 (0+206)
2.875
2.875
第 2 轮 (1392+51)
20.661
0.752
第 3 轮 (1440+216)
23.815
3.199
第 4 轮 (1648+344)
28.844
5.149
四轮累计 (4480+817)
76.196
11.976
0
20
40
60
80
Prefill 阶段矩阵运算量（TFLOPs）