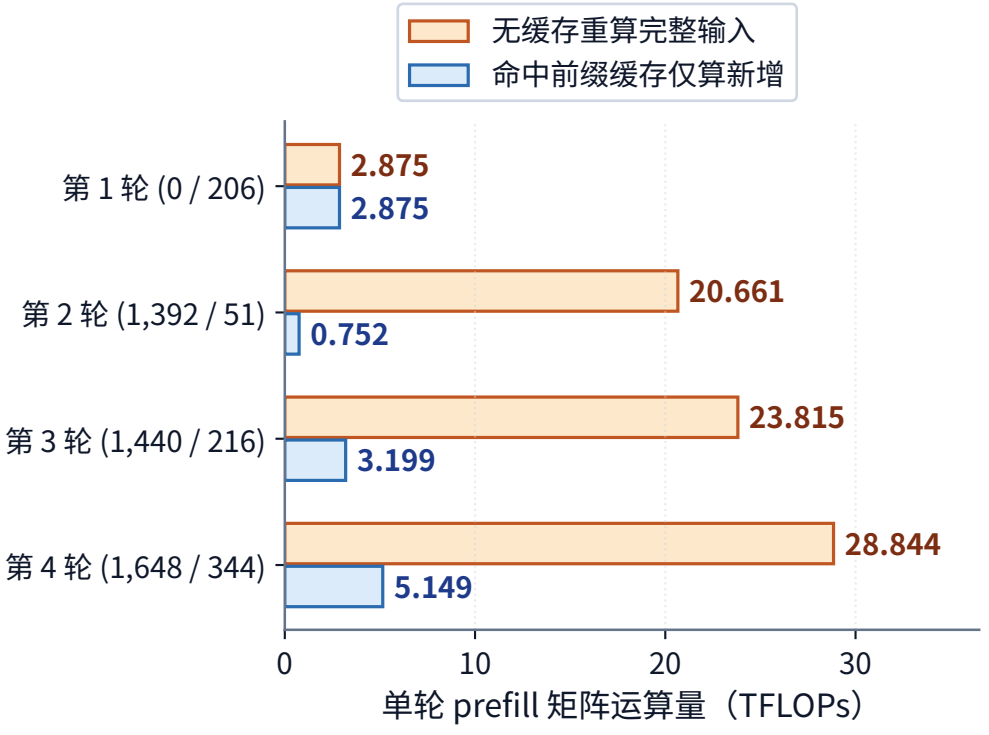
无缓存重算完整输入
命中前缀缓存仅算新增
第 1 轮 (0 / 206)
2.875
2.875
第 2 轮 (1,392 / 51)
20.661
0.752
第 3 轮 (1,440 / 216)
23.815
3.199
第 4 轮 (1,648 / 344)
28.844
5.149
0
10
20
30
单轮 prefill 矩阵运算量（TFLOPs）