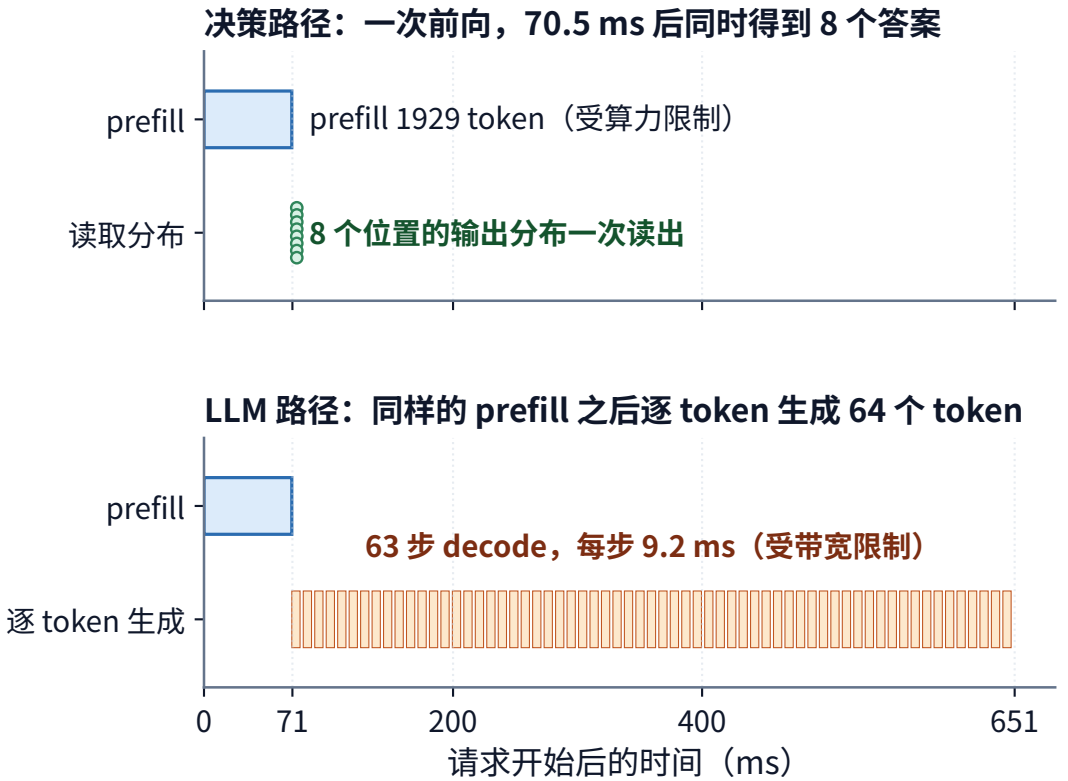
决策路径：一次前向，70.5 ms 后同时得到 8 个答案
prefill
prefill 1929 token（受算力限制）
读取分布
8 个位置的输出分布一次读出
LLM 路径：同样的 prefill 之后逐 token 生成 64 个 token
prefill
63 步 decode，每步 9.2 ms（受带宽限制）
逐 token 生成
0
71
200
400
651
请求开始后的时间（ms）